# Tema 2: Autocorrelación espacial

## Diplomado en Geoestadística y análisis espacial

**Econ. Alexis Adonai Morales Alberto**

2025

scidata
matemáticas para
la ciencia de datos

# Contenidos

1. Introducción.
2. Supuestos.
3. Estadísticos globales.
4. Estadísticos locales.
5. Heterocedasticidad espacial local.
6. Cross correlación espacial entre dos variables: Global y local.

# Introducción

Los métodos de estadística espacial también se denominan **análisis exploratorio de datos espaciales (ESDA)**. Las estadística espacial comprende métodos para probar la existencia de procesos de autocorrelación espacial. Las medidas de autocorrelación espacial se utilizan para evaluar la correlación de variables con respecto a la ubicación espacial.

**La autocorrelación espacial significa que las observaciones geográficamente cercanas son más similares entre sí que las distantes**. Esto hace posible predecir valores en un punto dado, conociendo los valores en otras ubicaciones.

# Introducción

La medida de autocorrelación espacial se puede utilizar de varias formas: **para probar la existencia de autocorrelación** espacial y características de la población; para determinar el **grado de autocorrelación**, por ejemplo, la distancia por encima de la cual las observaciones son independientes; determinar el modelo teórico apropiado para la estructura espacial observada o concluir sobre el proceso espacial.

Con base en las conclusiones de la ESDA, se puede **rechazar la hipótesis de la aleatoriedad espacial**, lo que abre el camino a la búsqueda de conglomerados espaciales (Anselin, 1999). Las conclusiones de la ESDA también son la base para la especificación espacial de los modelos.

# Introducción

En estadística espacial se utilizan dos tipos de medidas:**medidas globales y locales.**.

Por un lado, las medidas globales se plasman en un indicador de autocorrelación espacial o similitud general de regiones. Su ventaja es que es un indicador sintética y su desventaja es promediar.

Por otro lado, gracias a las estadísticas locales, que se determinan para cada región, se puede responder a la pregunta de **si la región está rodeada de regiones con valores altos o bajos o si es similar/diferente a las regiones vecinas**. Los valores de las estadísticas locales **no se generalizan para toda el área** analizada y se trabaja con información sobre la posición de cada región en relación con los vecinos.

# Introducción

El uso de técnicas ESDA **es el primer paso en el análisis de datos espaciales** y permite la detección de patrones de autocorrelación espacial globales y locales en los datos.

La **autocorrelación global** se puede medir mediante las estadísticas I de Moran global (Moran, 1950; Cliff & Ord, 1981) y C de Geary.

Las medidas locales más utilizadas incluyen las estadísticas locales Morans II y las estadísticas locales Gearys Ci, que forman parte del llamado **indicador local de asociación espacial (LISA)** (Anselin, 1995) y las estadísticas locales G Getis-Ord (Ord & Getis, 1995).

# Introducción

Las estadísticas globales **pueden identificar conglomerados y relaciones espaciales solo para todo el sistema**. Sin embargo, estas estadísticas se pueden desagregar en estadísticas locales, gracias a las cuales se pueden **detectar patrones de relaciones espaciales locales entre las regiones y sus vecinos**.

El cálculo de LISA permite detectar cuál de las regiones influye fuertemente en la formación de conglomerados locales y examinar los conglomerados locales no aleatorios, los denominados puntos calientes/-fríos (hot spots o cold spots), inestabilidad local (heterocedasticidad), observaciones atípicas significativas (Ministeri, 2003).

# Introducción

| Estadístico | Tipo | Tipo de medición | Interpretación | Funciones en `R` |
|---|---|---|---|---|
| Moran's I | Global | Una medida de autocorrelación espacial | $I > 0$: autocorrelación espacial positiva, los valores de observación a la distancia $d$ son similares<br>$I < 0$: autocorrelación espacial negativa, los valores de observación a la distancia $d$ son diferentes<br>$I = 0$: los valores de observación a la distancia d se distribuyen aleatoriamente | `moran ()`<br>`moran.test ()`<br>`moran.mc ()`<br>`moran.plot ()` |
| Geary's C | Global | Una medida de autocorrelación espacial | $0 < C < 1$: autocorrelación espacial positiva, los valores de observación a la distancia $d$ son similares<br>$1 < C < 2$: autocorrelación espacial negativa, los valores de observación a la distancia $d$ son diferentes | `geary ()`<br>`geary.test ()`<br>`geary.mc ()` |

Cuadro: Pruebas de autocorrelación espacial: Parte 1

# Introducción

| | | | | |
|---|---|---|---|---|
| Join-count | Global en grupos | Una medida de autocorrelación espacial | $H_0$ asume que no hay autocorrelación espacial, el valor $p > \alpha$ confirma esta hipótesis $H_1$ asume la existencia de autocorrelación espacial, valor $p < \alpha$ confirma esta hipótesis | `joincount.test()` `joincount.mc()` `joincount.multi()` |
| Local Moran's $I_i$ | Local | Junto con Local Geary, crea LISA, una medida de relaciones espaciales. | valor $p < \alpha$: rodeado por valores relativamente altos, un grupo de valores altos valor $p > (1-\alpha)$: un área rodeada por valores relativamente bajos, un grupo de valores bajos | `local.moran()` `localmoran.sad()` |
| Local Geary's $C_i$ | Local | Junto con Local Moran, crea LISA, una medida de diversidad espacial | valor $p > (1-\alpha)$: positivo, región rodeada de observaciones similares valor $p < \alpha$: negativo, región rodeada por diferentes observaciones | Existe el comando `usdm::lisa()` que permite al usuario calcular este estadístico, pero para rásteres. |

Cuadro: Pruebas de autocorrelación espacial: Parte 2

# Introducción

| | | | | |
|---|---|---|---|---|
| Local $G_i$, $G^*$ | Local | Medida de relaciones espaciales | $G_i > 0$: área rodeada por valores relativamente altos, clúster de alto valor<br>$G_i < 0$: área rodeada por valores relativamente bajos, clúster de valor bajo | `localG ()` |
| Local $H_i$, LOSH | Local | Medida de relaciones espaciales | Interpretado junto con las estadísticas $G^*$. Valores altos indican un entorno heterogéneo; valores bajos indican homogeneidad local. | `LOSH()` |
| Empirical Bayes index | Local | Medida de relaciones espaciales | Interpretado como las estadísticas I de Moran, utilizadas por interés (por ejemplo, número de casos / población) | `EBImoran.mc()` |

Cuadro: Pruebas de autocorrelación espacial: Parte 3

# Supuestos

La estadística espacial se basa en varios supuestos. El más importante de ellos es la **estacionariedad**, lo que significa que **los datos analizados deben tener una distribución normal con promedio y varianza constantes.**

Sin embargo, las estructuras de autocorrelación espacial no siempre son constantes en toda el área de estudio, por lo que es suficiente satisfacer **una estacionariedad débil, donde la media y la varianza son constantes, mientras que la autocorrelación depende solo de la distancia entre los objetos probados**.

# Supuestos

Los patrones espaciales deben ser isotrópicos; es decir, no deben depender de la dirección del estudio. Además, la forma del área estudiada afecta la intensidad, alcance y tipo de proceso espacial estimado, así como su importancia.

También existen los llamados efectos de borde (Fortin, Dale y Ver Hoef, 2002). Este problema se revela durante las observaciones en el borde del área de estudio. Estas regiones tienen menos vecinos que los objetos ubicados en el medio. Como resultado de este efecto, pueden aparecer diferencias en las estimaciones dependiendo de la matriz de vecindad adoptada (por ejemplo, de primer o segundo orden) (Cressie, 1993b).

# Supuestos

Un elemento común en econometría espacial es el llamado retardo/rezago espacial, que se determina para la variable examinada. El operador de rezago espacial es un promedio ponderado del valor de la variable en las regiones vecinas, de acuerdo con la matriz de ponderaciones espaciales declarada $W$.

Cuando se utiliza la matriz de vecindad de primer orden para el cálculo según el criterio de contigüidad, el rezago espacial será el promedio de los valores en las regiones limítrofes con el área examinada. Si se adoptara la matriz de segundo orden, el rezago espacial se determinaría a partir de los valores de los vecinos de estos vecinos. Una interpretación análoga ocurre cuando se usa la matriz de distancia o la matriz $k$ de los vecinos más cercanos.

# Estadísticos globales

Las medidas globales en estadística espacial permiten determinar la tendencia espacial general en la región. Su análisis permite una visión sintética de los datos. También proporcionan una buena base para una evaluación posterior más detallada del fenómeno.

# Estadístico global: I de Moran

El estadístico global I de Moran es probablemente la medida espacial más antigua, introducida por Moran en 1950 (Moran (1950)) y se usa para realizar pruebas de hipótesis de autocorrelación global.

Es una prueba basada en la covarianza, similar a una prueba de Pearson y el estadístico tiene la siguiente fórmula:

$$I = \frac{\Sigma_i \Sigma_j w_{ij} z_i z_j / S_0}{\Sigma_i z_i^2 / n}$$

Donde $z_i = x_i - \bar{x}$, $S_0 = \Sigma_i \Sigma_j w_{ij}$. $x_i$ es la observación en la unidad espacial $i, \bar{x}$ es el promedio de todas las unidades espaciales, $n$ es el total de unidades espaciales y $w_{ij}$ es un elemento de la matriz de pesos espaciales $W$. La matriz de pesos espaciales $W$ v se suele estandarizar por fila (las filas suman 1).

# I de Moran: Inferencia

La significancia de estadístico I de Moran puede evaluarse desde un enfoque paramétrico o no paramétrico; en esta presentación se adopta el enfoque no paramétrico. Para este objetivo se obtiene una distribución de la permutación del estadístico basado en una simulación de Monte Carlo de 10000 permutaciones.

La hipótesis nula asumida es la ausencia de autocorrelación, es decir, una distribución aleatoria de los valores.

# I de Moran: Interpretación

- Su media teórica es $\bar{I} = \frac{-1}{(n-1)}$ y tiende a 0.
- Signo positivo y significativo: conglomerados de valores similares. Es decir, puede ser valores altos, bajos, o ambos.
- Signo negativo y significativo: valores que alternan. Puede deberse a ouliers espaciales, puede deberse a heterogeneidad espacial (un patrón parecido a un tablero de ajedrez).

# I de Moran: Comparando MI's

- El estadístico de moran depende de la matriz de pesos espaciales W.
- Se puede comparar variables con la misma matriz de pesos espaciales, pero no se puede comprar variables (incluso la misma variable) con distintas matrices de pesos espaciales.
- Para comparabilidad, incluso cuando usas diferentes pesos espaciales, puedes usar valores estandarizados como zvalue del ejemplo anterior.

El estadístico de Moran es global, es decir que da cuenta de un patrón general en los datos, pero no da cuenta de la ubicación de los patrones. Por ejemplo, si es positivo indica que existe autocorrelación y que las unidades espaciales se agrupan en en valores similares, pero no indica dónde están esos grupos.

# I de Moran: Comparando MI's

La existencia de correlación positiva indica la existencia de conglomerados, pero no el por qué se dan estos conglomerados. El por qué puede deberse a dos motivos:

- Contagio verdadero: evidencia de conglomerados debido a interacción espacial. Por ejemplo, si una persona contagia a otras de gripe en un lugar cerrado.
- Contagio aparente: evidencia de conglomerados debido a heterogeneidad espacial. Por ejemplo, si un grupo de personas se reúne en un lugar cerrado que ya estaba contaminado.

# Gráfico de Moran

El gráfico de Moran nos permite empezar a conectar la idea de estadísiticos globales y locales. También es una guía para reconocer el tipo de autocorrelación con la que estamos tratando.

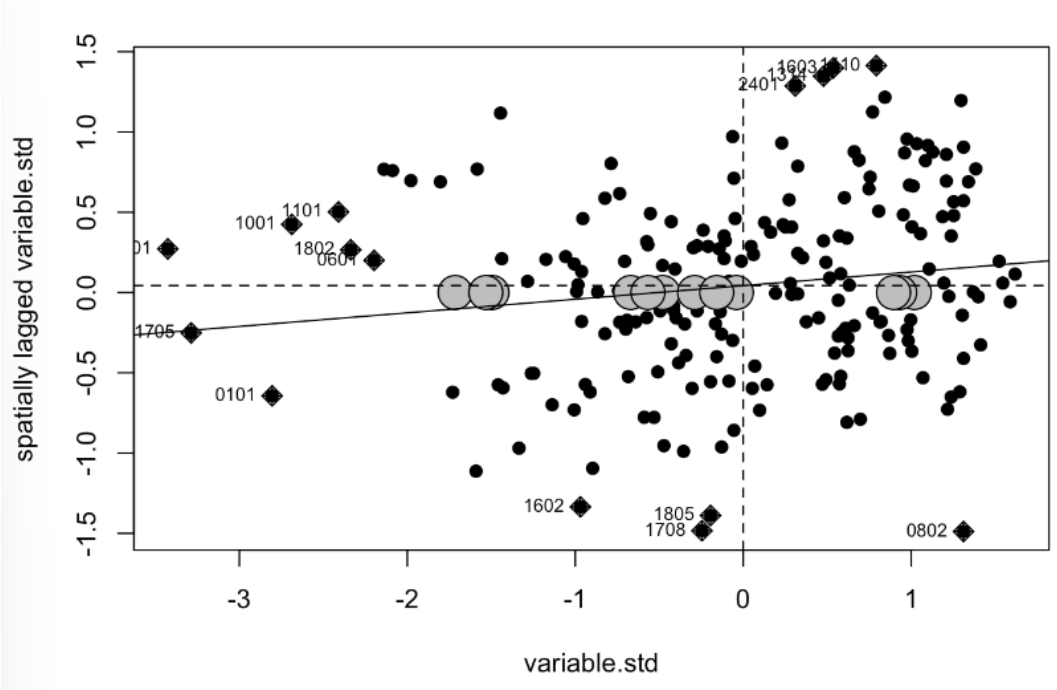


Figura: Ejemplo de Moran

# Gráfico de Moran

Se pueden tipiricar los cuadrantes:

- Cuadrante I y III: Autocorrelación positiva, conglomeradores de valores similares y unidades espaciales que son similares a sus vecinos.
- Cuadrante II y IV: Autocorrelación negativa, *outliers* espaciales y unidades espaciales que son diferentes a sus vecinos.

# Gráfico de Moran

Otra forma de entender los cuadrantes en mediante el tipo de autocorrelación:

- Cuadrante I: High-High, unidades espaciales que están sobre su media, rodeadas de vecinas que están sobre su media.
- Cuadrante II: Low-High, unidades espaciales que están debajo de su media, rodeadas de vecinas que están debajo de su media. Este cuadrante marca unidades espaciales candidatas a outliers espaciales.
- Cuadrante III: Low-Low, unidades espaciales que están debajo su media, rodeadas de vecinas que están debajo de su media.
- Cuadrante IV: High-Low, unidades espaciales que están sobre su media, rodeadas de vecinas que están debajo de su media. Este cuadrante marca unidades espaciales candidatas a outliers espaciales.

# Gráfico de Moran

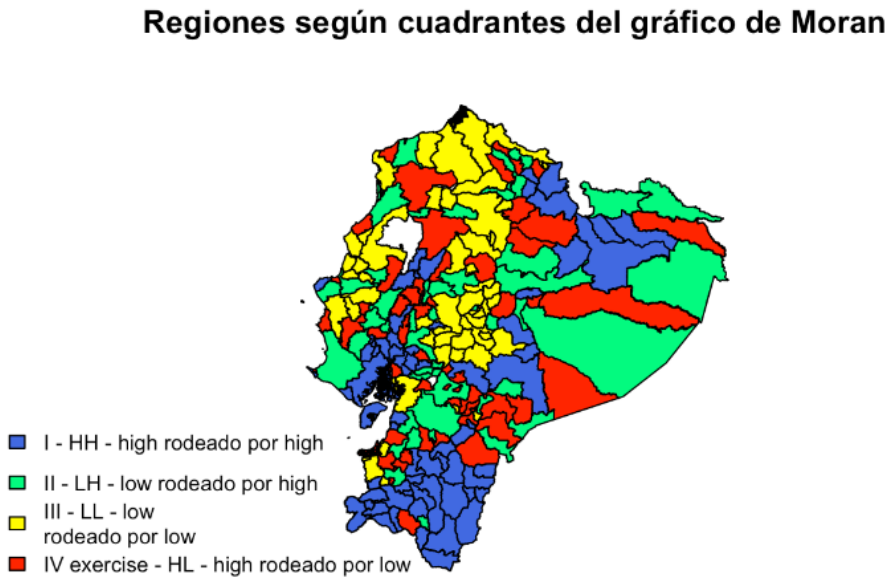


Figura: Ejemplo de mapa con I de Moran

# Estadístico Global de Geary

Propuesto por Geary en 1954, se basa en la noción de **disimilaridad**:

$$C = \frac{(n-1)}{2S_0} \frac{\Sigma_i \Sigma_j w_{ij} \left(x_i - x_j\right)^2}{\Sigma_i z_i^2}$$

Donde: $z_i = x_i - \bar{x}$, $S_0 ? \Sigma_i \Sigma_j w_{ij}$, $x_i$ es la observación en la unidad espacial $i$, $x_j$ es la observación en la unidad espacial $j$, $\bar{x}$ es el promedio de todas las unidades espaciales, $n$ es el total de unidades espaciales y $w_{ij}$ es un elemento de la matriz de pesos espaciales $W$.

# Estadístico Global de Geary

- El valor de $C$ está comprendido entre 0 y 2,asintóticamente sigue una distribución normal
- Asumiento ausencia de autocorrelación espacial, el valor esperado de $C$ es 1.
- Si $0 < C \leq 1$ ndica regiones similares (autocorrelación positiva). Esto es equivalente a que su valor $z$ ses megativo, $z < 0$.
- Si $1 < C \leq 2$ indica regiones con valores alternantes (autocorrelación negativa). Esto es equivalente a que su valor $z$ sea positivo, $z > 0$.
- El estadístico $C$ asume una matriz de pesos espaciales simétrica, en el caso de asimetría (como en el caso de los vecinos más cercanos), el estadísitico puede no ser de utilidad.

# Inferencia: Estadístico Global de Geary

La significancia de estadístico $C$ de Geary puede evaluarse desde un enfoque paramétrico o no paramétrico; en este texto se adopta principalemente el enfoque no paramétrico. Para este objetivo se obtiene una distribución de la permutación del estadístico basado en una simulación de Monte Carlo de 10000 permutaciones.

La hipótesis nula asumida es la ausencia de autocorrelación, es decir, una distribución aleatoria de los valores.

# Variograma

El semi-variogama es un diagrama bi-dimensional donde en el eje $x$ se muestra la distancia y en el eje $y$ se tiene:

$$\hat{\gamma}(\mathbf{h}) = \frac{1}{2\#N(\mathbf{h})} \sum (Z(s_i + \mathbf{h}) - Z(s_i))^2$$

# Variograma

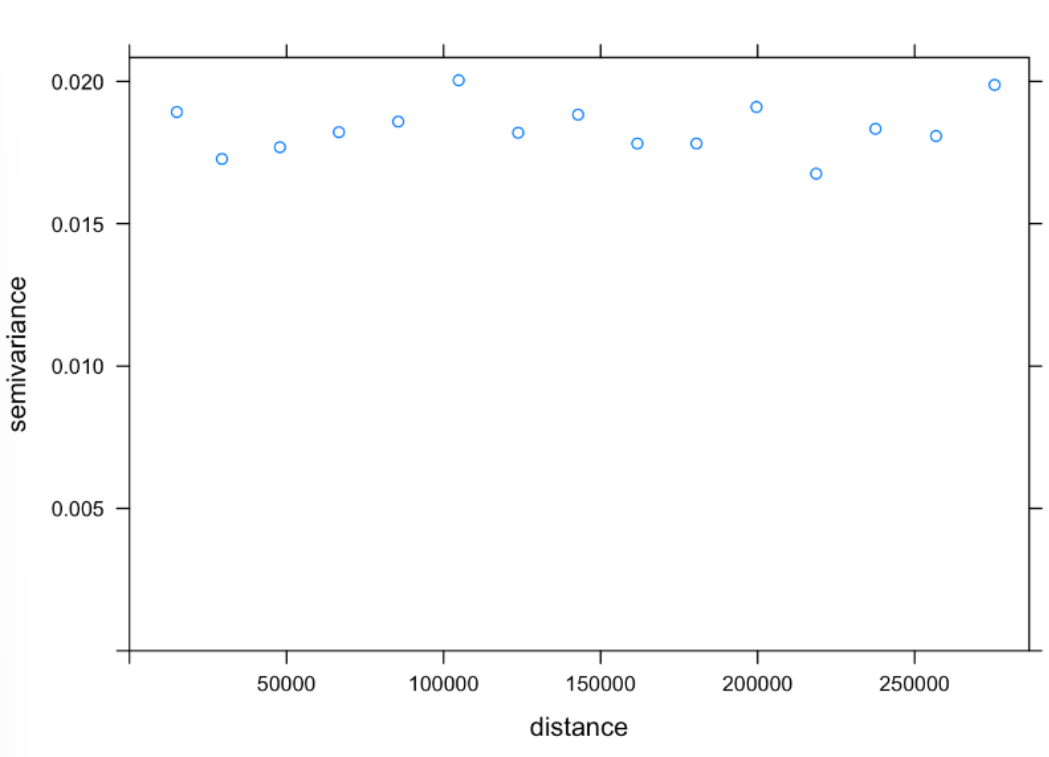


Figura: Ejemplo de Variograma

# Estadísticos Locales

Anselin (1995) propuso indicadores locales de relaciones espaciales (local indicators of spatial association - LISA). LISA incluye estadísticos locales: $I_i$ de Moran y $C_i$ de Geary.

El estadístico de Moran local permite la identificación de efectos de aglomeración espacial (similar al estadístico $G$ de Getis-Ord), mientras que el Geary local muestra similitudes y diferencias espaciales.

Las estadísticas locales de Moran brindan información sobre grupos de valor bajo o alto, mientras que los estadísticos locales de Geary muestran diferencias promedio entre el objeto y los vecinos, lo que ayuda a encontrar valores atípicos y patrones de similitud/diferencia.

# Estadísticos Locales

Estos estadísticos están relacionadas con sus contrapartes globales y se pueden utilizar para estimar el impacto de las estadísticas individuales en sus contrapartes globales.

Gracias a LISA, es posible identificar los denominados puntos calientes, es decir, centros con valores altos rodeados de valores bajos, así como clusters locales en ausencia de autocorrelación global. Las islas de alto valor pueden interpretarse no solo como puntos calientes, sino también como valores atípicos. Entonces, los estadísticos locales son un indicador de inestabilidad local y desviaciones locales del patrón de autocorrelación global.

# Estadísticos Locales

En resumen, los LISA nos presentan dos componentes:

- Un estadístico para cada unidad espacial que puede ser sujeto a pruebas de significancia.
- Cuantifica la relación entre el estadístico global y el local: la suma de los estadísticos locales es proporcional al estadístico global.

# Estadístico local: I de Moran

$$I_i = \frac{(x_i - \bar{x}) \sum_{j=1}^{n} w_{ij}(x_j - \bar{x})}{\sum_{i=1}^{n}(x_i - \bar{x})^2 / n}$$

Para evaluar la significancia se evalúa los valores

- p-value $< \alpha$: Las unidades espaciales que cumplen con esta condición indican tienen un índice local de Moran positivo y significativo. Esto significa que éstas unidades están rodeadas de valores altos de la variable analizada.
- p-value $> 1 - \alpha$: Las unidades espaciales que cumplen con esta condición indican tienen un índice local de Moran negativo y significativo. Esto significa que éstas unidades están rodeadas de valores bajos de la variable analizada.

# Ejemplo de mapa de I de Moran

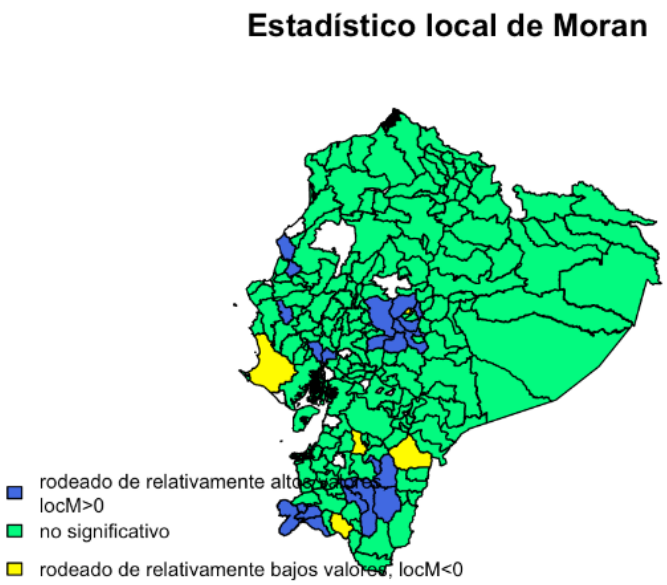


Figura: Ejemplo de I de Moran local

# Estadístico Local de Geary

El estadístico local de Geary se define como

$$C_i = \frac{1}{m_2} \sum_j w_{ij}(x_i - x_j)$$

Donde $m_2 = n^{-1} \sum_i (x_i - \bar{x})^2$. El valor esperado del Geary local se obtiene de la siguiente manera bajo aleatorización:

$$E(C_i) = \frac{2nw_i}{(n-1)}$$

# Estadístico Local: Getis-Ord $G_i$ y $G_i^*$

Los estadísticos $G_i$ y $G_i^*$ también son LISA y están dados por:

$$G_i = \frac{\sum_{j \neq i} w_{ij} x_j}{\sum_{j \neq i} x_j}$$

$$G_i^* = \frac{\sum_j w_{ij} x_j}{\sum_j x_j}$$

Donde $x_i$ es la observación en la unidad espacial $i$ y $w_{ij}$ es un elemento de la matriz de pesos espaciales $W$. Note que $G_i^*$ incluye a la unidad espacial analizada, mientras $G_i$ no. Tanto $G_i$ como $G_i^*$ requieren que $x$ sea positivo.

# Estadístico Local: Getis-Ord $G_i$ y $G_i^*$: Inferencia

Para la inferencia se asume una distribución $t$ para $G_i$ y $G_i^*$. La hipótesis nula es que $G_i = 0$.

- Valores positivos y significativos en la unidad espacial significan una agrupación de unidad espacial de alto valor (unidad analizada y vecinas), el llamado cluster de alto valor.
- Valores negativos del estadístico $G_i$ indican la existencia de un grupo de regiones con valores bajos de la variable examinada, es decir, la unidad espacial $i$ está rodeada por unidades espaciales similares de valor bajo.
- Valores positivos y significativas de Getis-Ord tienen un valor $p$ por debajo de 0.05, mientras que las estadísticas negativas y significativas tienen un valor $p$ por encima de 0.95.

# Ejemplo del estadístico local Getis-Ord

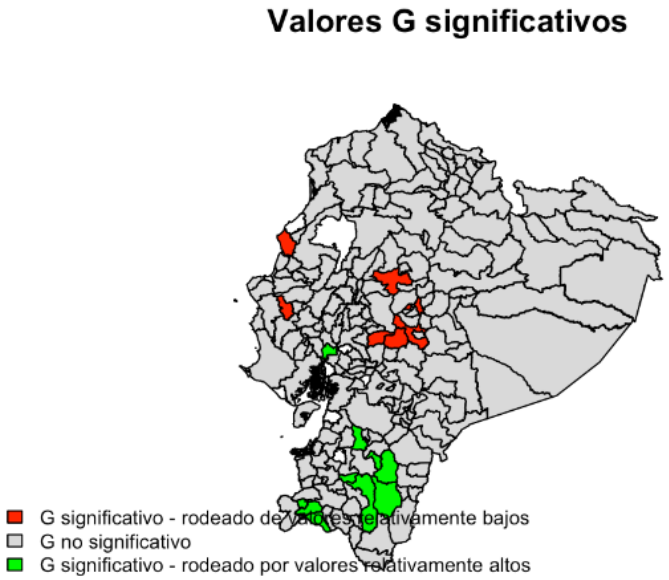


Figura: Ejemplo de G local

# Heterocedasticidad espacial local

Es posible extender el análisis de similitud de vecindades mediante la estabilidad de una variable en el espacio utilizando la medida de heterocedasticidad espacial local (LOSH) ($H_i$) (heterocedasticidad espacial local), complementaria a la $G_i$.

El análisis combinado de ambos indicadores permite medir la similitud e inestabilidad de una variable en el espacio. El estadístico $H_i$ mide la varianza de una variable en la vecindad, indicando áreas con variabilidad uniforme y no uniforme, de manera análoga a la medida de autocorrelación en el indicador $G_i$.

# Heterocedasticidad espacial local

La medida local de heterocedasticidad espacial LOSH ($H_i$) viene dada por la fórmula:

$$H_i = \frac{\sum_j w_{ij}|e_j|^\alpha}{\sum_j w_{ij}}$$

Donde $e_j = x_j - \bar{x}_j$, $w_{ij}$ es un elemento de la matriz de pesos espaciales $W$. Si $\alpha = 1$, $H_i$ corresponde a una medida de desviación absoluta, si $\alpha = 2$, $H_i$ corresponde a una medida de varianza.

# Interpretación de $H_i$ y $G_i$

Efectos espaciales usando $H_i$ y $G_i$. Fuente: Yamagata and Seya (2019).

| | $H_i$ **alto** | $H_i$ **bajo** |
|---|---|---|
| $G_i$ alto | Un punto caliente con condiciones locales heterogéneas | Un punto caliente con unidades espaciales similares |
| $G_i$ bajo | Condiciones locales heterogéneas pero a un nivel medio bajo (poco frecuente) | Condiciones locales homogéneas y un nivel medio bajo |

Cuadro: Interpretación

# Ejemplo de $H_i$ y $G_i$

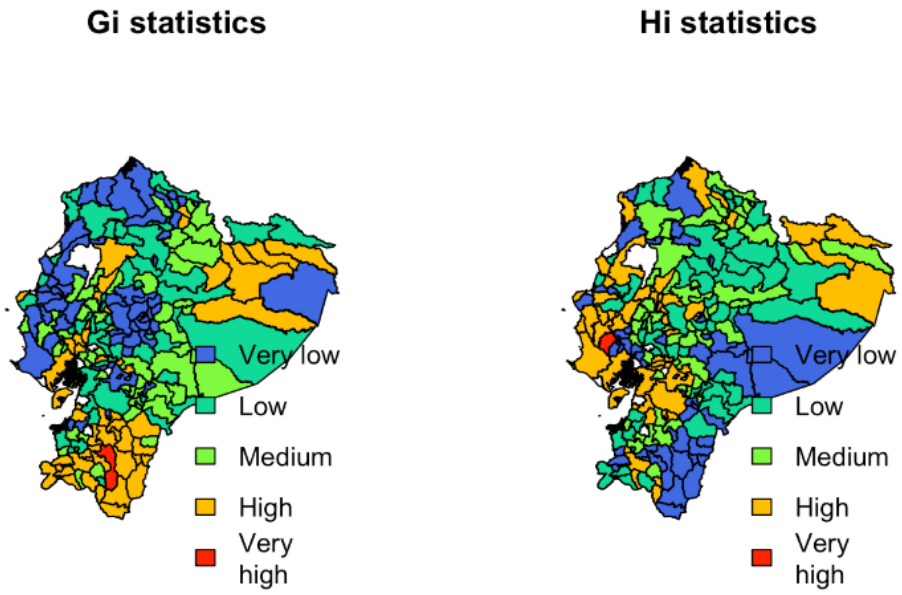


Cuadro: Mapa con $H_i$ y $G_i$

# Cross correlación espacial entre dos variables: Global

Introducido por Chen (2015), el índice de cross-correlación espacial global (GSCI por sus siglas en inglés) está dado por:

$$R_c = x^T W y$$

y es un estadístico escalado entre $[-1, 1]$; $x$ y $y$ son las variables estudiadas y $W$ es la matriz de pesos especiales.
Este es una medida indirecta que calcula correlación relacionada con distancia.

# Cross correlación espacial entre dos variables: Global

También se tiene una relación entre correlación tradicional de dos variables y $R_c$:

$$R_0 = R_c + R_p$$

Donde $R_0$ es un índice de correlación de Pearson, donde la dependencia consiste de relación entre valores de la variable y relaciones en el espacio. $R_c$ es el coeficiente GSCI y $R_p$ es una cross-correlación parcial, que expresa la influencia directa de las variables sin efectos espaciales.

# Cross correlación espacial entre dos variables: Local

También se tiene medidas locales de cross-correlación, el índice de cross-correlación espacial local (LSCI por sus siglas en inglés):

$$R_i^{(xy)} = x_i \sum_j w_{ij} y_j$$

$$R_j^{(yx)} = y_i \sum_j w_{ij} x_j$$

Donde $i$ y $j$ son diferentes unidades espaciales y $w_{ij}$ son elementos de la matriz de pesos espaciales $W$.

El GSCI refleja la suma de correlaciones cruzadas entre dos (todos) elementos cualesquiera, mientras que el LSCI mide la correlación cruzada entre un elemento dado y todos los demás en el sistema.

# Referencias


- Arbia, G. (2014). *A Primer for Spatial Econometrics: With Applications in R* (1st ed.). Palfrave mcmillan, India.
- Paul, E. J. (2014). *Spatial Econometrics: From Corss-Sectional Data to Spatial Panels* (1st ed.). Springer, London.
- LeSage, P. J. and Kelley, P. R. (2009). *Introduction to Spatial Econometrics* (1st ed.). CRC Press, USA.