Dependencia temporal, autocorrelación simple y parcial

Diplomado: Pronósticos y Series de Tiempo con RStudio y Python
Modulo: Estructura y dependencia temporal

Morales Alberto Alexis Adonai

2026

Índice

1 Introducción

Índice

1. Introducción
2. Modelos con tendencia

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria
4. Caminata Aleatoria con Deriva

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria
4. Caminata Aleatoria con Deriva
5. Función de Autocorrelación (ACF)

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria
4. Caminata Aleatoria con Deriva
5. Función de Autocorrelación (ACF)
6. Función de Autocorrelación Parcial (PACF)

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria
4. Caminata Aleatoria con Deriva
5. Función de Autocorrelación (ACF)
6. Función de Autocorrelación Parcial (PACF)
7. Comparación ACF vs PACF

Índice

1. Introducción
2. Modelos con tendencia
3. Modelo de Caminata Aleatoria
4. Caminata Aleatoria con Deriva
5. Función de Autocorrelación (ACF)
6. Función de Autocorrelación Parcial (PACF)
7. Comparación ACF vs PACF
8. Conclusiones

Sección 1

Introducción

Introducción

- Hasta ahora, hemos aprendido que una serie de tiempo se define por su intervalo de tiempo y frecuecia, lo cual la dinstingue de otros datos (como los transversales o de panel). Pero además, se ha comprendido que la serie de tiempo presenta atributos o componentes tales como: Tendencia, estacionalidad y error, los vuales rigen el comportamiento deterministico de esta clase de series.
- En esta presentación se verá lo que implica que una serie de tiempo presente una estructura de dependencia temporal, que si bien, en la definción se indica que es un conjunto de datos aleatorios, hay algunos casos donde la serie de tiempo llega a tener estructuras deterministicas mediante la dependencia temporal.

Introducción

- Para abordar lo anterior se comenzará con la definición de dependencia temporal, así como los modelos de caminata aleatoria y caminata aleatoria con deriva.
- Y también se revisará en qué consisten las funciones de autocorrelación simple y parcial, que son instrumentos estadísicos que permiten encontrar si dicha correlación temporal, es significativa o no y por ende validar la autocorrelación.

Sección 2

Modelos con tendencia

Tendencia determinística

Un modelo simple con tendencia lineal es

$$Y_t = \beta_0 + \beta_1 t + \varepsilon_t$$

donde

- t es el tiempo
- ε_t es ruido blanco

Ejemplo en R

```r
set.seed(123)

t <- 1:100
y <- 2 + 0.5*t + rnorm(100,0,3)

df <- data.frame(t,y)

ggplot(df,aes(t,y))+
geom_line()+
geom_smooth(method="lm",se=FALSE)+
theme_minimal()+
labs(title="Serie con tendencia lineal")
```

Ejemplo en R

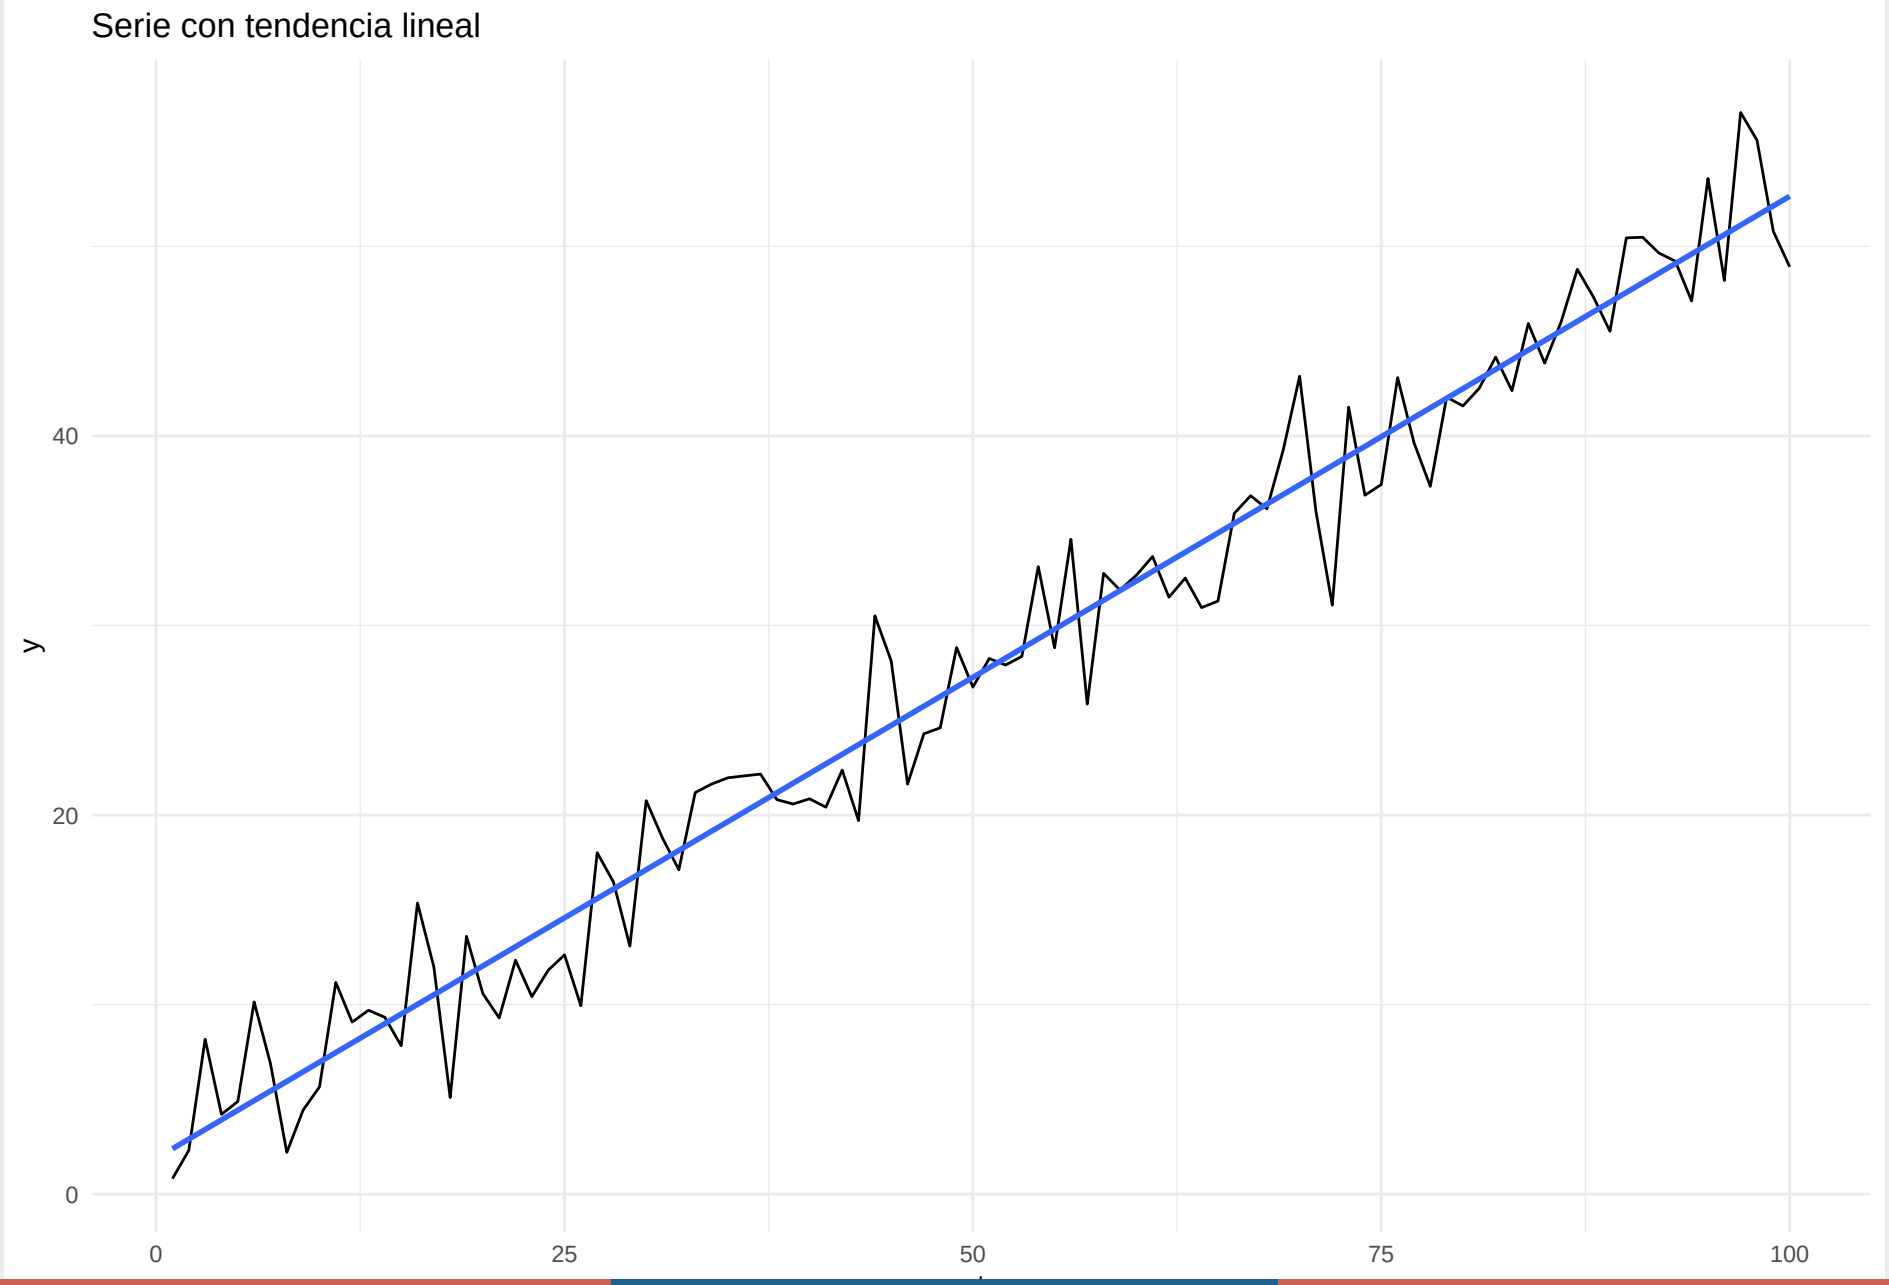

Sección 3

Modelo de Caminata Aleatoria

Definición

El modelo de caminata aleatoria es

$$Y_t = Y_{t-1} + \varepsilon_t$$

donde

$$\varepsilon_t \sim WN(0, \sigma^2)$$

Propiedades:

- proceso no estacionario
- varianza creciente
- fuerte dependencia temporal

Simulación

```r
set.seed(123)

rw <- cumsum(rnorm(200))

df_rw <- data.frame(
t = 1:200,
y = rw
)

ggplot(df_rw,aes(t,y))+
geom_line()+
theme_minimal()+
labs(title="Caminata Aleatoria")
```

Simulación

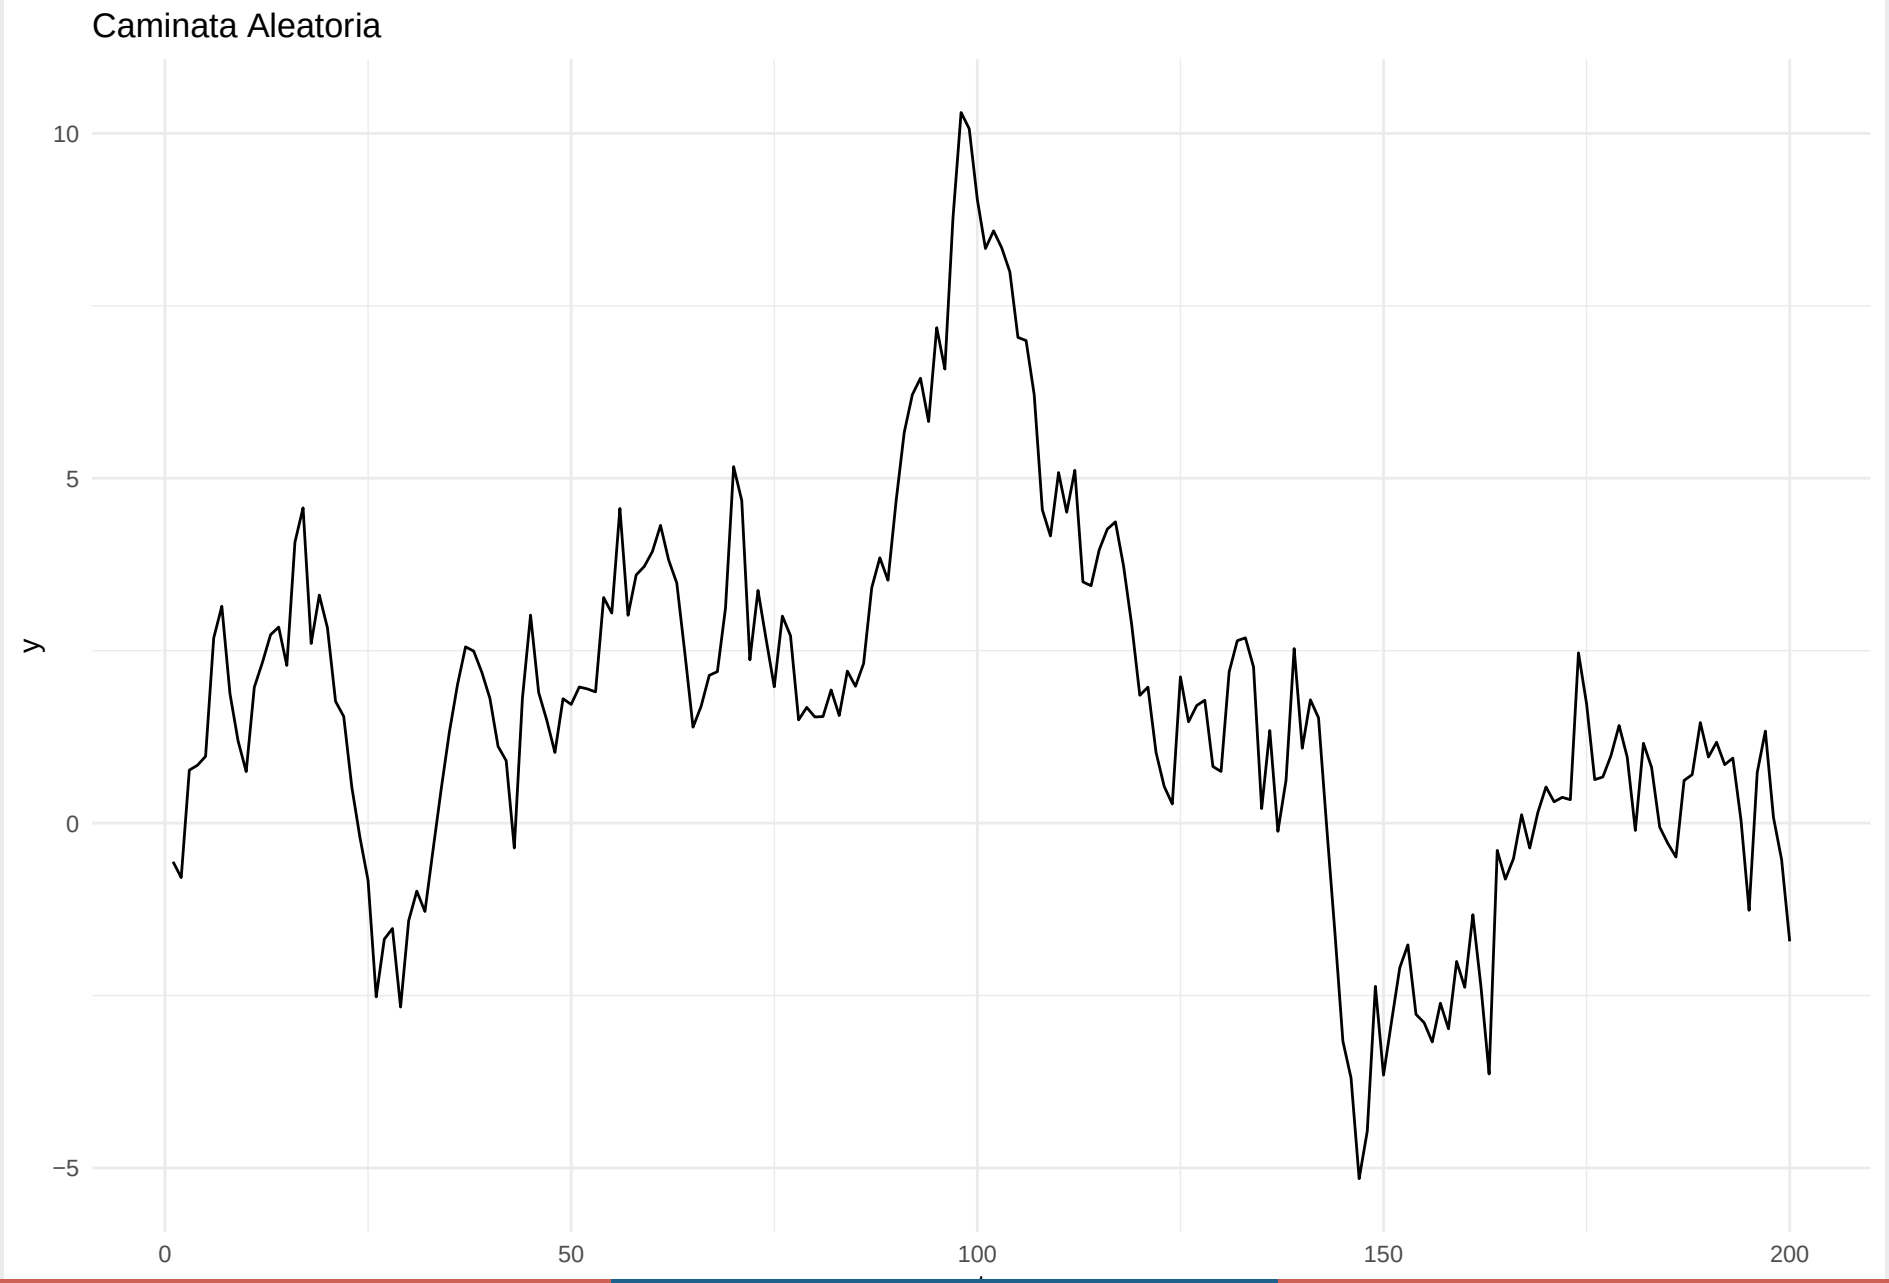

Sección 4

Caminata Aleatoria con Deriva

Definición

La caminata aleatoria con deriva se define como

$$Y_t = \delta + Y_{t-1} + \varepsilon_t$$

donde δ representa una tendencia promedio por periodo.

Simulación

```r
set.seed(123)
e <- rnorm(200)
y <- numeric(200)
delta <- 0.3
for(i in 2:200){
y[i] <- delta + y[i-1] + e[i]
}
df <- data.frame(t=1:200,y=y)
ggplot(df,aes(t,y))+
geom_line()+
theme_minimal()+
labs(title="Caminata Aleatoria con Deriva")
```

Simulación

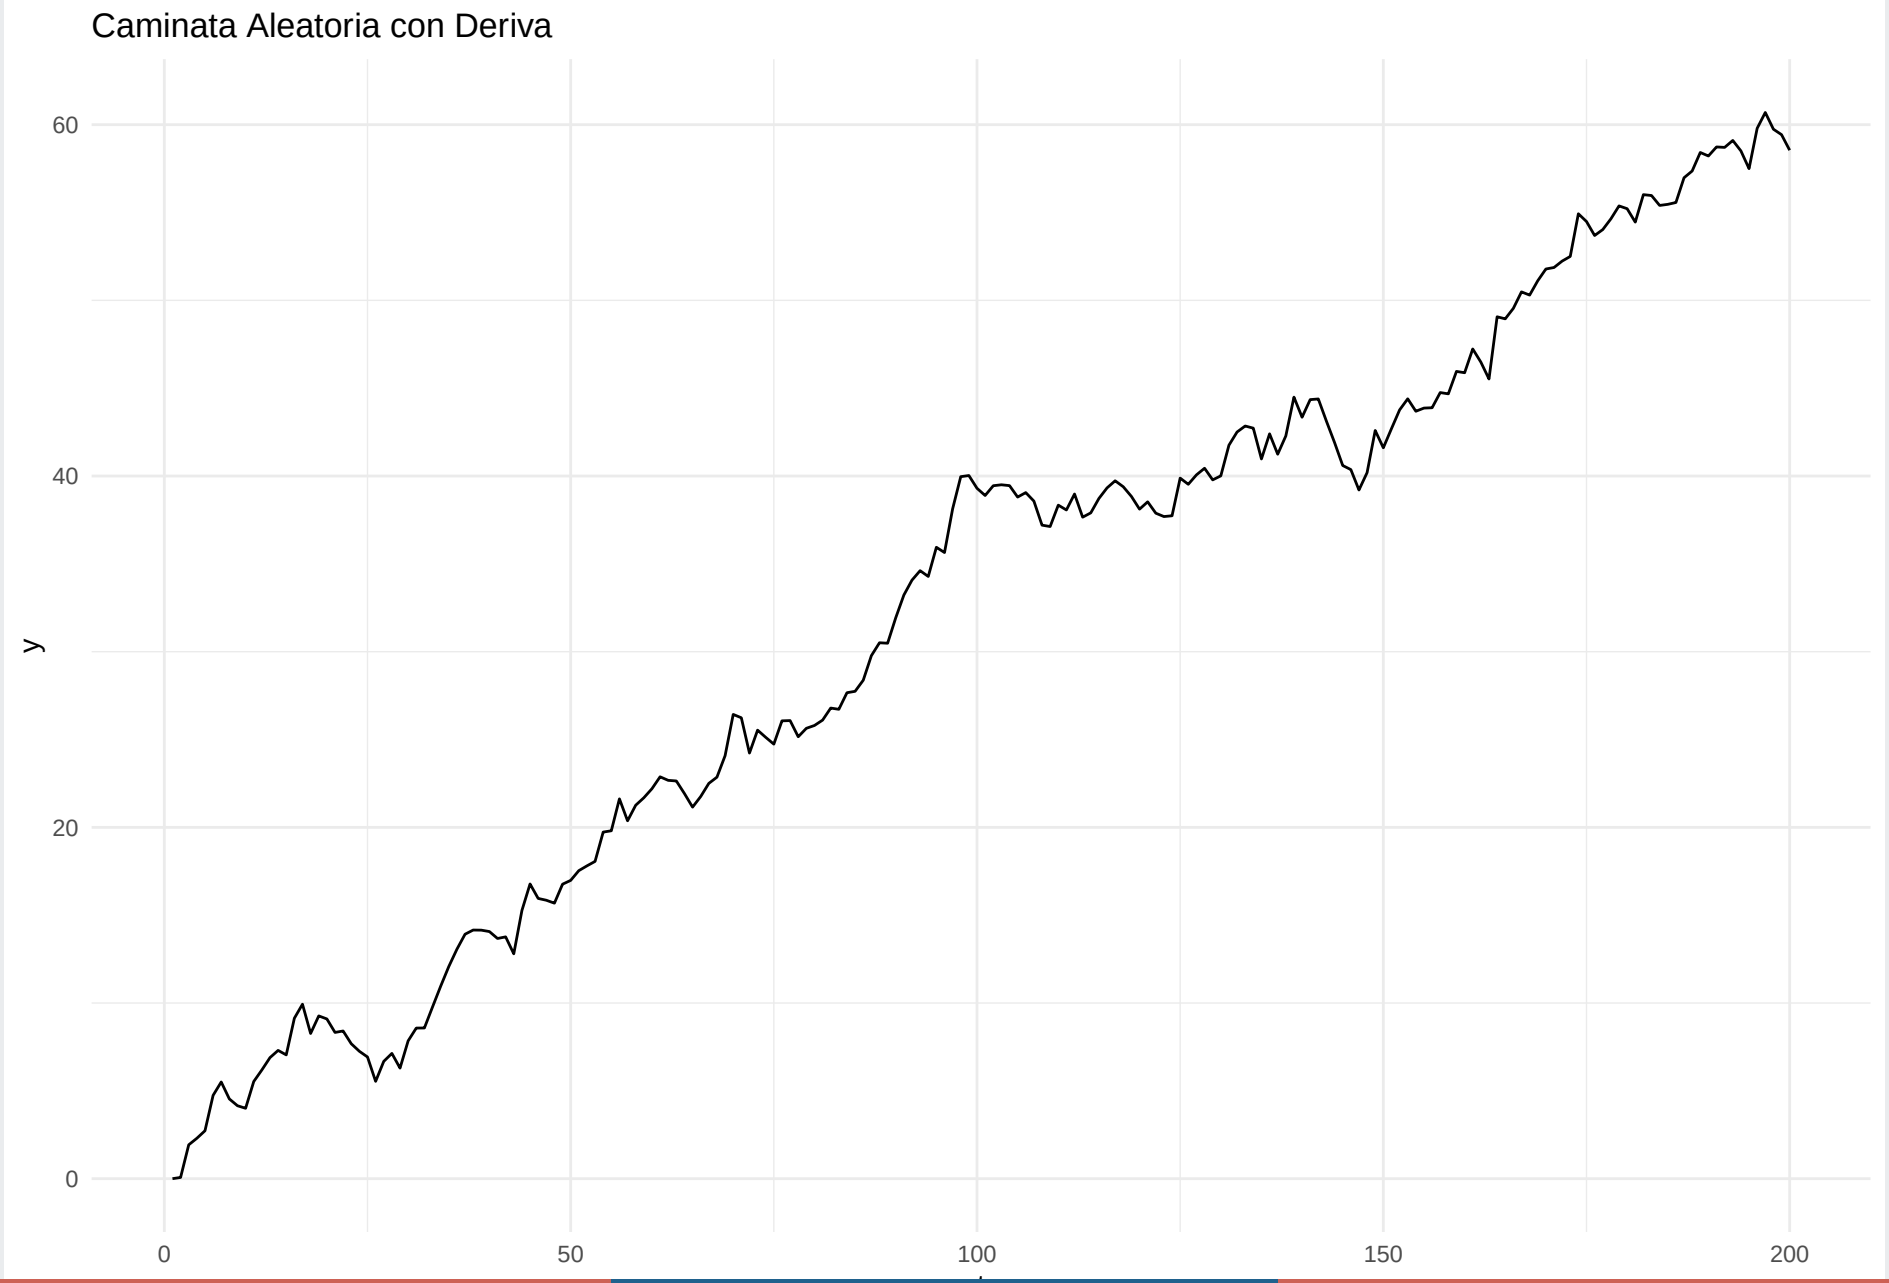

Sección 5

Función de Autocorrelación (ACF)

Definición

La función de autocorrelación mide la relación entre valores separados por un rezago k:

$$\rho_k = \frac{Cov(Y_t, Y_{t-k})}{Var(Y_t)}$$

Interpretación:

- mide dependencia temporal
- permite identificar estructura del modelo

Estimación muestral

$$r_k = \frac{\sum_{t=k+1}^{T}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^{T}(Y_t - \bar{Y})^2}$$

Gráfico ACF

```
acf(rw, lag.max = 20)
```

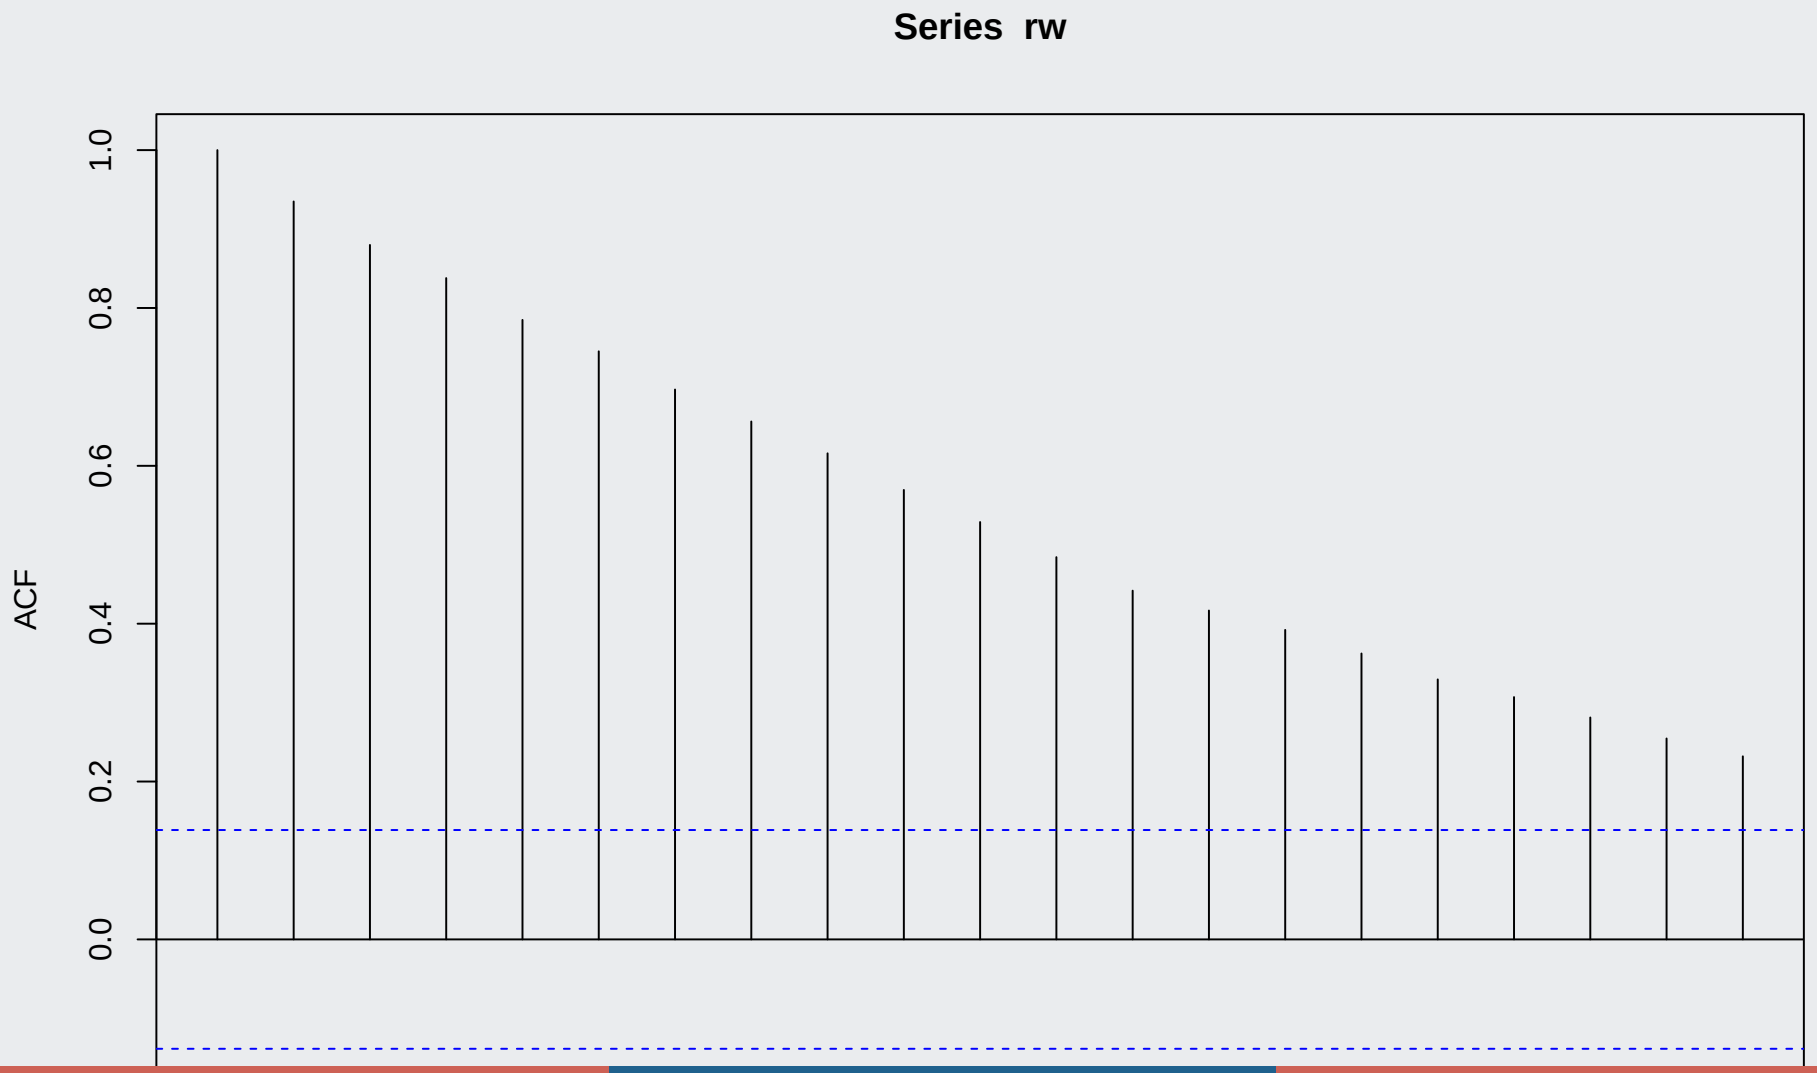

Sección 6

Función de Autocorrelación Parcial (PACF)

Definición

La PACF mide la correlación entre Y_t y Y_{t-k} eliminando el efecto de los rezagos intermedios.

Representación mediante regresión

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_k Y_{t-k} + \varepsilon_t$$

El coeficiente ϕ_k corresponde a la PACF en rezago k.

Gráfico PACF

```r
pacf(rw, lag.max = 20)
```

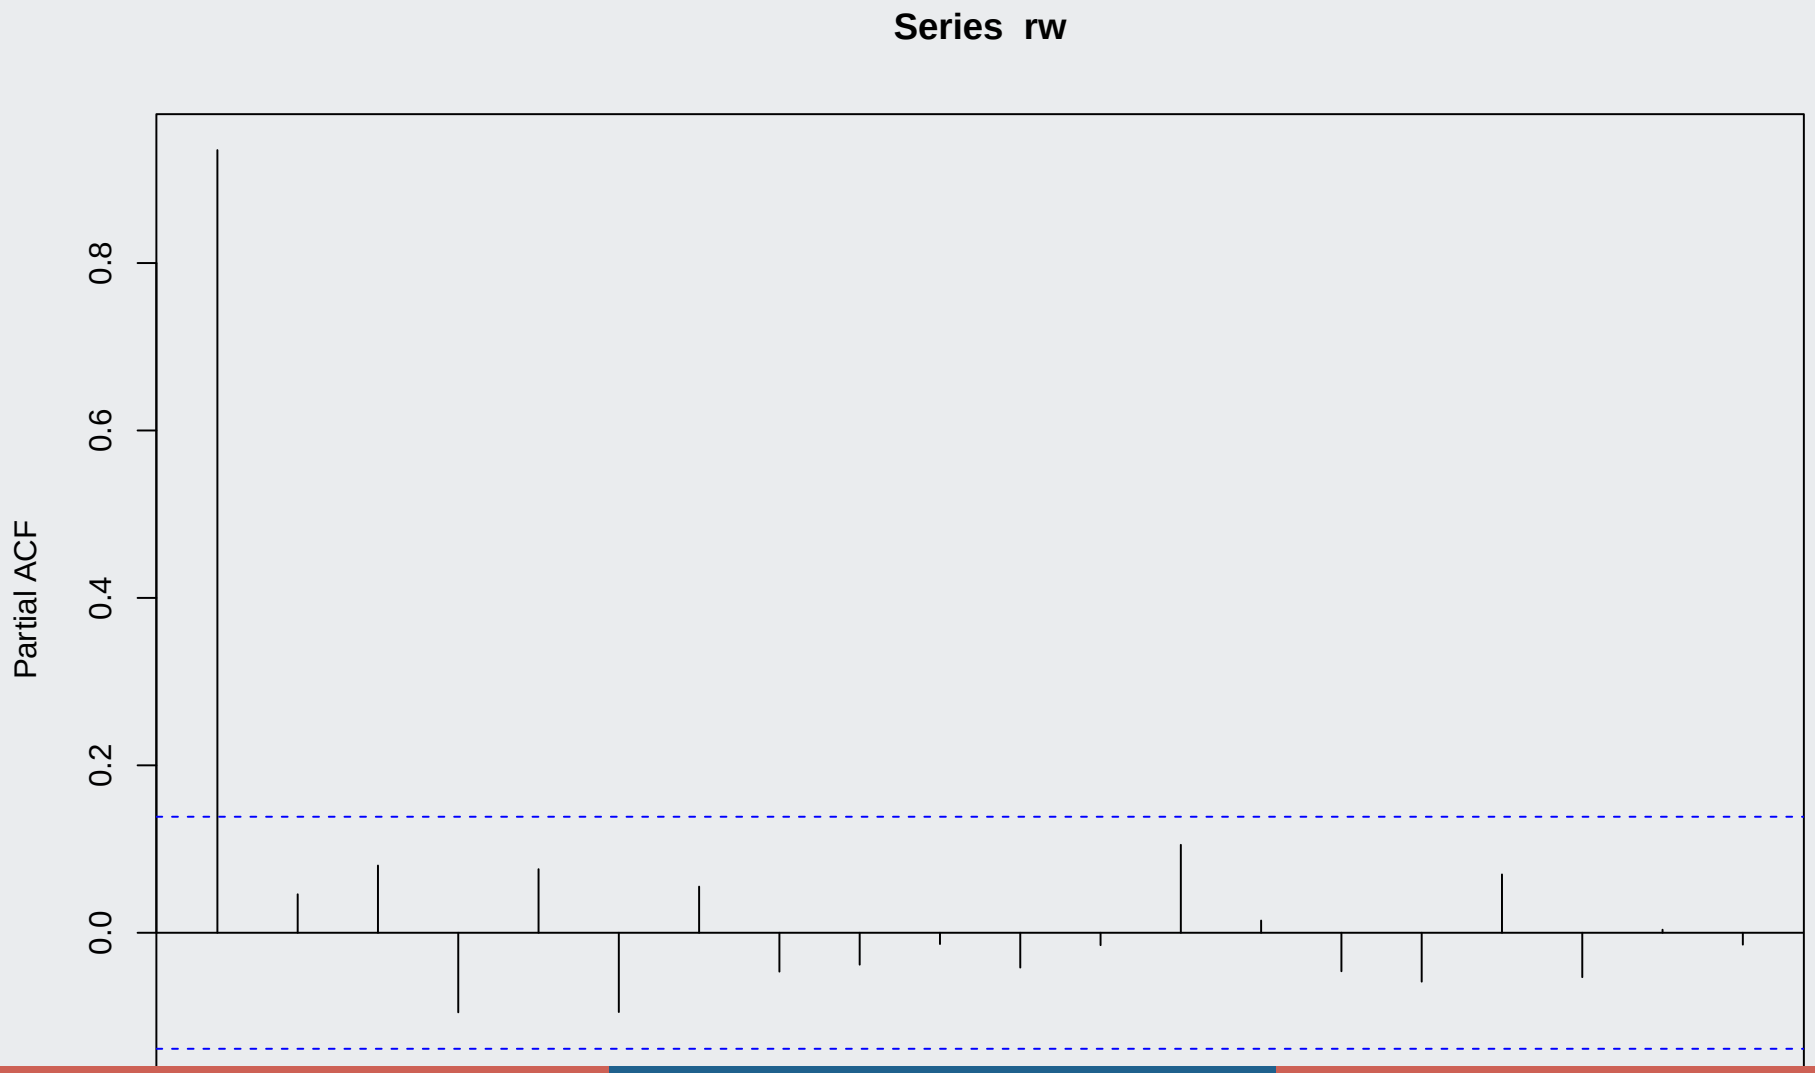

Sección 7

Comparación ACF vs PACF

Comparación ACF vs PACF

Función	Uso
ACF	Identificar MA
PACF	Identificar AR
Ambas	Diagnóstico de modelos ARIMA

Patrones comunes:

- AR(p): PACF corta en p
- MA(q): ACF corta en q
- ARMA: ambas decrecen

Sección 8

Conclusiones

Conclusiones

- Las series con tendencia describen crecimiento sistemático.
- La caminata aleatoria es un proceso no estacionario.
- La caminata con deriva introduce crecimiento promedio.
- ACF y PACF son herramientas fundamentales para identificar modelos de series de tiempo.