Estacionariedad y modelos clásicos

Diplomado: Pronósticos y Series de Tiempo con RStudio y Python
Modulo: Estacionariedad y modelos clásicos

Morales Alberto Alexis Adonai

2026

Índice

1 Descomposición temporal de las series de tiempo

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad
3. Modelo lineal estacionario

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad
3. Modelo lineal estacionario
4. Conceptos fundamentales de procesos no estacionarios

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad
3. Modelo lineal estacionario
4. Conceptos fundamentales de procesos no estacionarios
5. Pruebas estadísticas para la detección de estacionariedad

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad
3. Modelo lineal estacionario
4. Conceptos fundamentales de procesos no estacionarios
5. Pruebas estadísticas para la detección de estacionariedad
6. ¿Qué se debe hacer en caso de no presentar un proceso estacionario?

Índice

1. Descomposición temporal de las series de tiempo
2. Proceso estocástico y la estacionariedad
3. Modelo lineal estacionario
4. Conceptos fundamentales de procesos no estacionarios
5. Pruebas estadísticas para la detección de estacionariedad
6. ¿Qué se debe hacer en caso de no presentar un proceso estacionario?
7. Filtros de series de tiempo

Sección 1

Descomposición temporal de las series de tiempo

Introducción

Una serie de tiempo es una secuencia de observaciones ordenadas cronológicamente. En muchos fenómenos económicos, demográficos y sociales, las series de tiempo presentan patrones sistemáticos que pueden descomponerse en distintos componentes con el objetivo de facilitar su análisis, interpretación y modelación.

La **descomposición temporal** consiste en separar una serie de tiempo en componentes estructurales que capturan distintos tipos de variabilidad.

Componentes de una serie de tiempo

Sea Y_t una serie de tiempo observada en el instante t. Clásicamente, se consideran los siguientes componentes:

- **Tendencia (T_t)**: refleja el comportamiento de largo plazo de la serie.
- **Estacionalidad (S_t)**: patrón periódico que se repite con una frecuencia fija.
- **Ciclo (C_t)**: fluctuaciones de mediano plazo asociadas a ciclos económicos o estructurales.
- **Componente irregular o aleatorio (I_t)**: variación no explicada por los componentes anteriores.

En la práctica, el componente cíclico suele incorporarse dentro de la tendencia o del componente irregular, dependiendo del método utilizado.

Modelo de descomposición aditiva

El **modelo aditivo** se utiliza cuando la magnitud de las fluctuaciones estacionales es aproximadamente constante a lo largo del tiempo.

La formulación matemática es:

$$Y_t = T_t + S_t + I_t$$

Cada componente contribuye de manera lineal a la serie observada.

Estimación de la tendencia (modelo aditivo)

Una forma común de estimar la tendencia es mediante **promedios móviles centrados**.

Para una serie con estacionalidad de periodo m, la tendencia se estima como:

$$\hat{T}_t = \frac{1}{m} \sum_{j=-k}^{k} Y_{t+j}, \quad k = \frac{m-1}{2}$$

Cuando m es par, se emplean promedios móviles dobles para centrar la tendencia.

Estimación del componente estacional (modelo aditivo)

Una vez estimada la tendencia, se calcula la serie desestacionalizada:

$$Y_t - \hat{T}_t = S_t + I_t$$

El componente estacional se obtiene promediando los valores correspondientes a cada estación:

$$\hat{S}_j = \frac{1}{n_j} \sum_{t \in j} (Y_t - \hat{T}_t)$$

donde $j = 1, \dots, m$ denota la estación y n_j el número de observaciones en dicha estación.

Finalmente, se impone la restricción:

$$\sum_{j=1}^{m} \hat{S}_j = 0$$

Estimación del componente irregular (modelo aditivo)

El componente irregular se obtiene como el residuo del modelo:

$$\hat{I}_t = Y_t - \hat{T}_t - \hat{S}_t$$

Este componente captura choques aleatorios, errores de medición y variaciones no sistemáticas.

Modelo de descomposición multiplicativa

El **modelo multiplicativo** es apropiado cuando la amplitud de las fluctuaciones estacionales crece o disminuye proporcionalmente al nivel de la serie.

La formulación es:

$$Y_t = T_t \times S_t \times I_t$$

Equivalentemente, aplicando logaritmos:

$$\log(Y_t) = \log(T_t) + \log(S_t) + \log(I_t)$$

Estimación de la tendencia (modelo multiplicativo)

La tendencia se estima nuevamente mediante promedios móviles:

$$\hat{T}_t = \frac{1}{m} \sum_{j=-k}^{k} Y_{t+j}$$

La diferencia con el modelo aditivo radica en la forma de calcular los demás componentes.

Estimación del componente estacional (modelo multiplicativo)

Se obtiene la serie ajustada por tendencia:

$$\frac{Y_t}{\hat{T}_t} = S_t \times I_t$$

El índice estacional se calcula como:

$$\hat{S}_j = \frac{1}{n_j} \sum_{t \in j} \frac{Y_t}{\hat{T}_t}$$

Posteriormente, se normaliza imponiendo la restricción:

$$\frac{1}{m} \sum_{j=1}^{m} \hat{S}_j = 1$$

Estimación del componente irregular (modelo multiplicativo)

El componente irregular se obtiene como:

$$\hat{I}_t = \frac{Y_t}{\hat{T}_t \times \hat{S}_t}$$

Valores cercanos a 1 indican ausencia de perturbaciones relevantes.

Comparación entre modelos aditivo y multiplicativo

- El modelo **aditivo** es adecuado cuando la variabilidad estacional es constante.
- El modelo **multiplicativo** es preferible cuando la estacionalidad depende del nivel de la serie.
- El uso de logaritmos permite transformar un modelo multiplicativo en uno aditivo.

La elección del modelo debe basarse en el análisis gráfico y en el comportamiento empírico de la serie.

Conclusiones

La descomposición temporal es una herramienta fundamental para:

- Comprender la estructura interna de una serie de tiempo.
- Facilitar la modelación y el pronóstico.
- Identificar patrones de largo y corto plazo.

Los modelos aditivo y multiplicativo ofrecen marcos conceptuales simples pero poderosos para el análisis exploratorio de series temporales.

Sección 2

Proceso estocástico y la estacionariedad

Procesos estocásticos y estacionarios

Un **proceso estocástico** es una familia de variables aleatorias que, en general, estan relacionadas entre sí y siguen una ley de distribución conjunta. Se denota por:

$$Y_t(\omega), t = \cdots, t-2, t-1, t, t+1, t+2, \cdots,$$
$$\cdots, Y_{t-2}, Y_{t-1}, Y_t, Y_{t+1}, Y_{t+2}, \cdots,$$
$$[Y_t]_{-\infty}^{+\infty}$$

Dicho de otra manera, se le denomina un **proceso estocástico** a un conjunto de variables u observaciones aleatorias que están sujetas en el tiempo ***t***. Es decir, cada variable X_t es una observación que está definida sobre el mismo espacio de probabilidad Ω. El conjunto de índices **T** se denomina **espacio de tiempo**, donde dichos espacios son en tiempo discreto o continuo.

Características de un proceso estacionario

Un proceso estocástico se puede caracterizar bien por su función de distribución o por sus momentos, los cuales se explican a continuación:

1. **Función de distribución**:

Para conocer la función de distribución de un proceso estocástico es necesario conocer las funciones de distribución univariantes de cada una de las variables aleatorias del proceso, $F[Y_t]$, $\forall t$, y las funciones bivariantes correspondientes a todo par de variables aleatorias del proceso, $F[Y_{t_i}, Y_{t_j}]$, $\forall (t_i, t_j)$, y todas las funciones trivariantes, etc.

Características de un proceso estacionario

En resumen, la función de distribución de un proceso estocástico incluye todas las funciones de distribución para cualquier subconjunto finito de variables aleatorias del proceso:

$$F\left[Y_{t_1}, Y_{t_2}, \cdots, Y_{t_n}\right] \quad \forall \ (t_1, t_2, \cdots, t_n)$$

Características de un proceso estacionario

2. **Momentos del proceso estocástico**:

Como suele ser muy complejo determinar las características de un proceso estocástico através de su función de distribución se suele recurrir a caracterizarlo a través de los dos primeros momentos.

a) El primer momento de un proceso estocástico viene dando por el conjunto de **medias** de todas las variables aleatorias del proceso:

$$E\left(Y_t\right) = \mu_t < \infty, \;\; t = 0, \pm 1, \pm 2, \cdots,$$

Características de un proceso estacionario

b) El segundo momento de un **proceso estocástico** esta centrado en lo que viene dando por el conjunto de las **varianzas** de todas las variabes aleatorias del proceso y por las **covarianzas** entre todo par de variables aleatorias:

$$V\left(Y_t\right) = E\left[Y_t - \mu_t\right]^2 = \sigma_t^2, \ < \infty \ t = 0, \pm 1, \pm 2, \cdots,$$
$$cov\left(Y_t, Y_s\right) = E\left[Y_t - \mu_t\right]\left[Y_s - \mu_s\right] = \gamma_{t,s}, \ \forall t, s \ (t \neq s)$$

Proceso estocásticos estacionarios

Dentro de la teoría de series de tiempo, el objetivo de utilizar los **proceso estocásticos** es determinar qué clase de **proceso estocástico** es capaz de generar la serie temporal (a estudiar) con el fin de caracterizar el comportamiento de la serie y predecir en el futuro (con base al planteamiento de una estructura autorregresiva, de medias móviles, etc).

El concepto de **estacionariedad** se puede caracterizar bien, en términos de la función de distribución o de los momentos del proceso. En el primer caso, se hablará de *estacionariedad en el sentido estricto* y, en el segundo, de *estacionariedad de segundo orden o en covarianza*.

Proceso estocásticos estacionarios

1. **Estacionariedad estricta**:

Un proceso estocástico, Y_t, es estacionario en el sentido estricto si y solo si:

$$F\left[Y_{t_1}, Y_{t_2}, \cdots, Y_{t_n}\right] = F\left[Y_{t_1+k}, Y_{t_2+k}, \cdots, Y_{t_n+k}\right]$$
$$\forall\ (t_1, t_2, \cdots, t_n)$$

Es decir, si la función de distribución de cualquier conjunto finito de n variables aleatorias del proceso no se altera si se desplaza k periodos en el tiempo.

Proceso estocásticos estacionarios

2. **Estacionariedad en covarianza**:

Un **proceso estocástico**, Y_t, es estacionario en covarianza si y solo si:

a) Es estacionario en media, es decir, todas las variables aleatorias del proceso tienen la misma media y es finita:

$$E\left(Y_t\right) = \mu \ < \infty \ \forall t$$

b) Todas las variables aleatorias tienen la misma varianza y es finita, es decir, la dispersión en torno a la media constante a lo largo del tiempo, es la misma para todas las varianzas del proceso:

$$V\left(Y_t\right) = E\left[Y_t - \mu\right]^2 = \sigma_Y^2 < \infty, \ \forall t$$

Proceso estocásticos estacionarios

c) Las autocovarianzas solo dependen del número de periodos de separación entre las variables y no del tiempo, es decir, la covarianza lineal entre dos variables aleatorias del proceso que disten k periodos de tiempo es la misma que existe entre cualesquiera otras dos variables que estén separadas también en k periodos, independientemente del momento concreto de tiempo al que estén referidas.

$$cov\left(Y_t, Y_s\right) = E\left[Y_t - \mu\right]\left[Y_s - \mu\right] = \gamma_{|t-s|} = \gamma_k < \infty, \ \forall k$$

Proceso estocásticos estacionarios

Por lo tanto, un proceso estocástico es estacionario en covarianza si solo si:

$$E\left(Y_t\right) = \mu < \infty \tag{A}$$

$$cov\left(Y_t, Y_s\right) = \begin{cases} V\left(Y_t\right) = \sigma_Y^2 < \infty \; t = s \\ \gamma_{|t-s|} = \gamma k < \infty \; t \neq s \end{cases} \tag{B}$$

Proceso estocásticos estacionarios

Un proceso estocástico estacionario en covarianza está caracterizado si se conoce:

$$\mu,\ V\left(Y_t\right),\ \gamma_k,\ k=\pm 1,\pm 2,\cdots$$

Si un proceso estocástico es estacionario en covarianza y su distribución es **normal**, es estacionario en sentido estricto.

Proceso estocásticos estacionarios

En resumen, los procesos **estocásticos estacionarios** son aquellos donde **la media y la varianza** de un conjunto de observaciones Y_t, son constantes en el tiempo **T** y además que existe la **covarianza** entre dos periodos de tiempo. Donde el valor de está depende sólo de la distancia o rezago entre estos dos periodos, y no del tiempo en el cual se calculó la covarianza.

$$E\left(Y_t\right) = \mu \tag{1}$$
$$Var\left(Y_t\right) = E\left(Y_t - \mu\right)^2 = \sigma^2$$
$$Cov\left(Y_t, Y_{t-k}\right) = \gamma_k = E\left[\left(Y_t - \mu\right) - \left(Y_{t-k} - \mu\right)\right]$$

Ruido blanco

El proceso estocástico más sencillo, y que por lo general, es en el que más se basa para afirmar la estacionariedad, es denominado **ruido blanco** y consiste en una secuncia de variables aleatorias de media cero, varianza constante y covarianzas nulas. Se detonará habitualmente por $a_t,\ t = 0, \pm 1, \pm 2, \cdots,$:

$$E\left(a_t\right) = 0,\ \forall t$$
$$V\left(a_t\right) = \sigma^2,\ \forall t$$
$$cov\left(a_t, a_s\right) = 0,\ \forall t \neq s$$

Ruido blanco

Así, un proceso de **ruido blanco**, $a_t \sim RB(0, \sigma^2)$, es estacionario si la varianza σ^2 es finita con una función de autocovarianzas (FACV):

$$\gamma_k = \sigma^2,\ k = 0\ y\ \gamma_k 0,\ k > 0$$

Y la función de autocorrelación (FAC):

$$\gamma_k = 1,\ \ k = 0\ y\ \gamma_k = 0,\ \ k > 0$$

Sección 3

Modelo lineal estacionario

Modelo lineal estacionario

Dentro de los procesos estocásticos estacionarios se considerará únicamente la clase de procesos lineales que se caracterizan porque se pueden representar como una combiación lineal de variables aleatorias. En el caso de procesos estacionarios con distribución normal y media cero, la teoría de procesos estocásticos señala que, bajo condiciones muy generales, Y_t se puede expresar como combinación lineal de los valores pasados infinitos de Y_t más una innovación de ruido blanco:

$$Y_t = \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \pi_3 Y_{t-3} + \cdots + a_t \ \forall t \ t = 1, 2, \cdots \tag{2}$$

Modelo lineal estacionario

Las condiciones generales que ha de cumplir el proceso son:

a) Que el proceso sea **no anticipante**, es decir, que el presente no venga determinado por el futuro, luego el valor de Y_t en el momento t no puede depender de valores futuros de Y_t o de las innovaciones a.

b) Que el proceso sea **invertible**, es decir, que el presente dependa de forma convergente de su propio pasado, lo que implica que la influencia de Y_{t-k} en Y_t ha de ir disminuyendo conforme se aleje del pasado. Esta condición se cumple si los parámetros del modelo general (2) cumplen con la siguiente resricción:

$$\sum_{i=1}^{\infty} \pi_i^2 < \infty$$

Modelo lineal estacionario

El modelo (2), se puede escribir de forma más compacta en términos del operador de retardos:

$$
\begin{aligned}
Y_t &= \left(\pi_1 L + \pi_2 L^2 + \cdots\right) Y_t + a_t \\
\left(1 - \pi_1 L - \pi_2 L^2 - \cdots\right) Y_t &= a_t \\
\Pi_\infty\left(L\right) Y_t &= a_t
\end{aligned}
$$

Otra forma de escribir el modelo (2) es:

$$
\begin{aligned}
Y_t &= \frac{1}{\Pi_\infty\left(L\right)} a_t = \Psi_\infty\left(L\right) a_t \qquad (2.1) \\
Y_t &= \left(1 - \psi_1 L + \psi_2 L^2 + \cdots\right) a_t \\
Y_t &= a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \psi_3 a_{t-3} + \cdots \quad t = 1, 2, \cdots
\end{aligned}
$$

Modelo lineal estacionario

Es decir, el valor de Y_t se puede representar como la combinación lineal del ruido blanco a_t y su pasado infinito. El modelo (2.1) cumple la condicón de estacionariedad si los parámetros del modelo satisfacen la siguiente restricción:

$$\sum_{i=1}^{\infty} \psi_i^2 < \infty$$

Esta restricción implica que el valor presente depende de forma convergente de las innovaciones pasadas, es decir, la influencia de la innovación a_{t-k} va desapareciendo conforme se aleja en el pasado.

Sección 4

Conceptos fundamentales de procesos no estacionarios

Procesos no estacionarios

Dentro de los procesos no estacionarios, se deben identificar esta clase de modelos que se le denoniman **deterministas** y esto se debe a que son estructuras que no se pueden estimar, ya que generarían procesos de regresión espuria al no cumplir con las condiciones de un **proceso estocástico estacionario**.

Caminata aleatoria.- Modelo que describe que el comportamiento de Y_t esta dado por el valor anterior Y_{t-1} más un choque aleatorio μ_t matemáticamente:

$$Y_t = Y_{t-1} + \mu_t \tag{2}$$

Procesos no estacionarios

Caminata aleatoria con deriva.- En está función determinista, solo se visualiza la deriva de Y_t y si su movimiento es hacia arriba o hacia abajo, algo parecido a AR(1):

$$Y_t = \delta + Y_{t-1} + \mu_t \tag{3}$$

Ejemplo de caminata aletoria

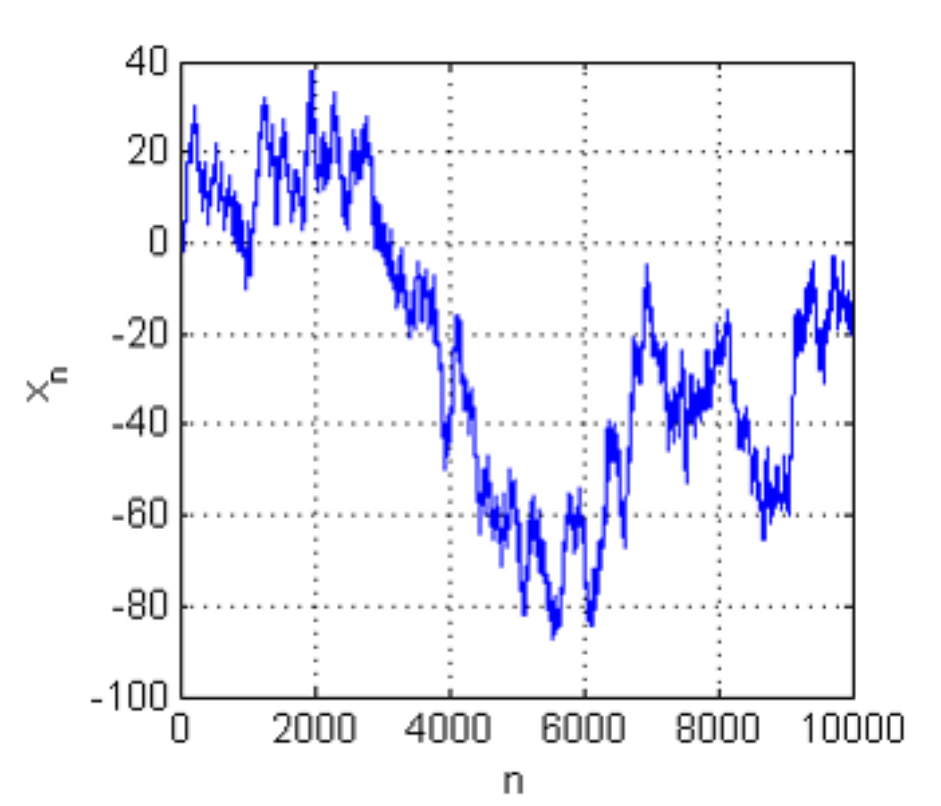

Proceso estocástico de raíces unitarias

Las condiciones de un proceso estocástico, es que los datos no presenten correlación en el tiempo ***T***, dado a ***n*** periodos. Por lo tanto, los términos de no estacionariedad, caminata aleatoria, raíz unitaria y tendencia estocástica, se consideran sinónimos.

Como una condición particular para el modelaje ARIMA/ARMA, establece que las series deben ser estocásticamente estacionarias, es por ello que la correlación no debe presentarse en la serie.

$$\begin{gathered} Y_t = \rho Y_{t-1} + \mu_t \\ -1 \leq \rho \leq 1 \end{gathered} \tag{4}$$

¿Cómo se puede identifcar un proceso estacionario?

Existen pruebas estadísticas y gráficas que permiten evaluar la existencia de ρ dentro de una serie de tiempo, estas son las siguiente:

- Pruebas estadísticas:
  - Dickey-Fuller.
  - Dickey-Fuller Aumentada.
  - Phillips-Perron
  - KPSS
  - Zivot Andrews
- Pruebas gráficas:
  - ACF (Función de autocorrelación simple)
  - PACF (Función de autocorrelación parcial)

Pruebas gráficas

1. **ACF**

Función de autocorrelación simple (ACF).- Para entender el concepto se considera una serie de tiempo débilmente estacionaria. Por lo tanto, la función de autocorrelación simple es una colección de autocorrelaciones en diferentes rezagos. El coeficiente de correlación entre X_t y X_{t-k} es llamada o denominada ***autocorrelación de retardo-k*** de X_t y comúnmente se detona por ρ_k:

$$\rho_k = \frac{Cov\left(x_t, x_{t-k}\right)}{\sqrt{Var\left(x_t\right) Var\left(x_{t-k}\right)}} = \frac{Cov\left(x_t, x_{t-k}\right)}{var\left(x_t\right)} = \frac{\gamma_k}{\gamma_0}$$

Ejemplo ACF

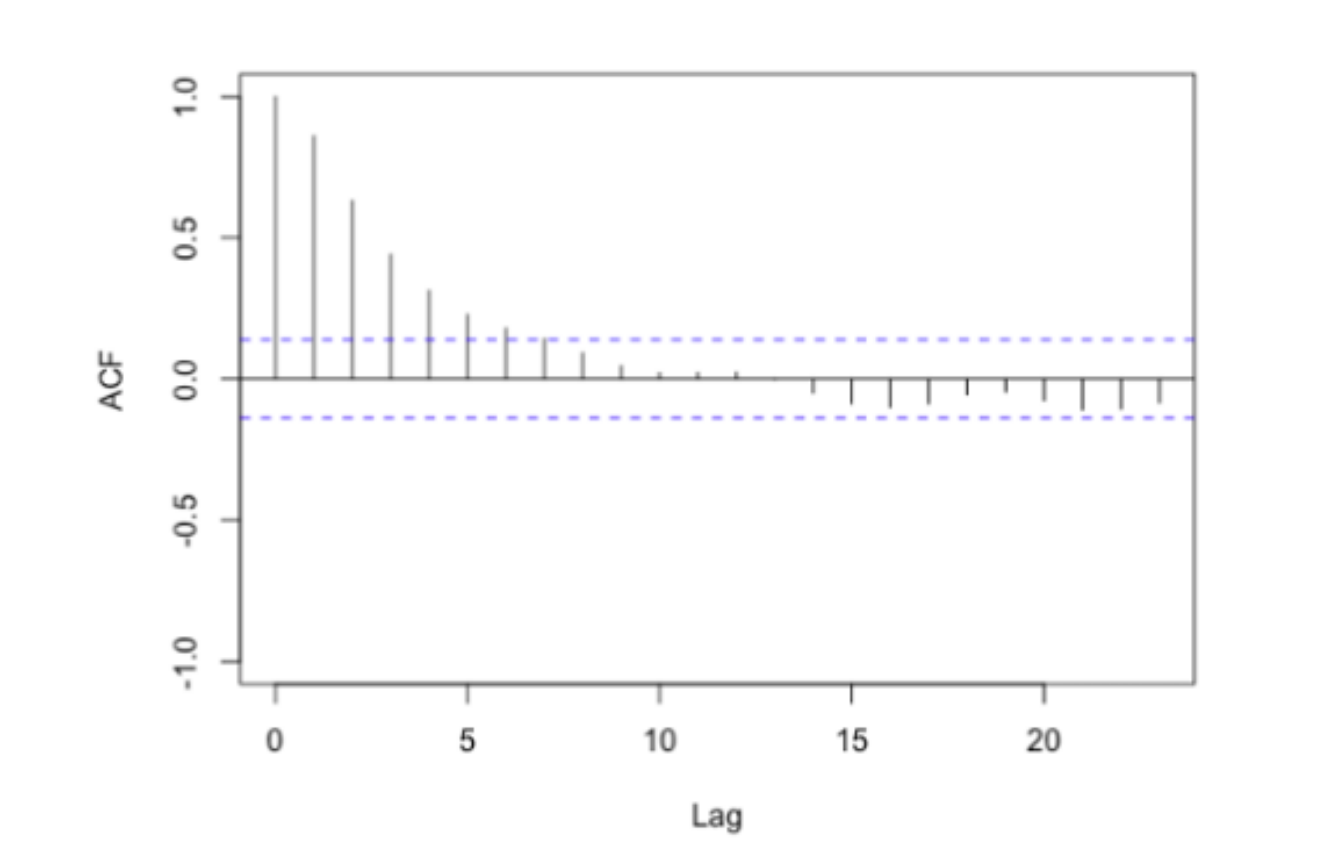

2. **PACF**

Función de autocorrelación parcial (PACF).- Es una prueba asociada a la de función de autocorrelación simple, que busva medir la correlación entre valores de una secuencia temporal, es por ello que se deonomina la función de autocorrelación parcial. Es el conjunto de coeficientes de autocorrelación parcial desde el retado $K = 1$, hasta un máximo posible de retardos igual a la mitad de la cantidad de valores contenidos en la secuencia., se realiza mediante el estadístico insesgado para ρ_{kk} :

$$\rho_{kk} = \frac{\rho_k - \sum_{j=1}^{k-1} \rho_{k-j} \left(\rho_{k-1j} - \rho_k * \rho_{k-1k-j} \right)}{1 - \sum_{j=1}^{k-1} \rho_j \left(\rho_{k-1j} - \rho_k * \rho_{k-1k-j} \right)}$$

Ejemplo PACF

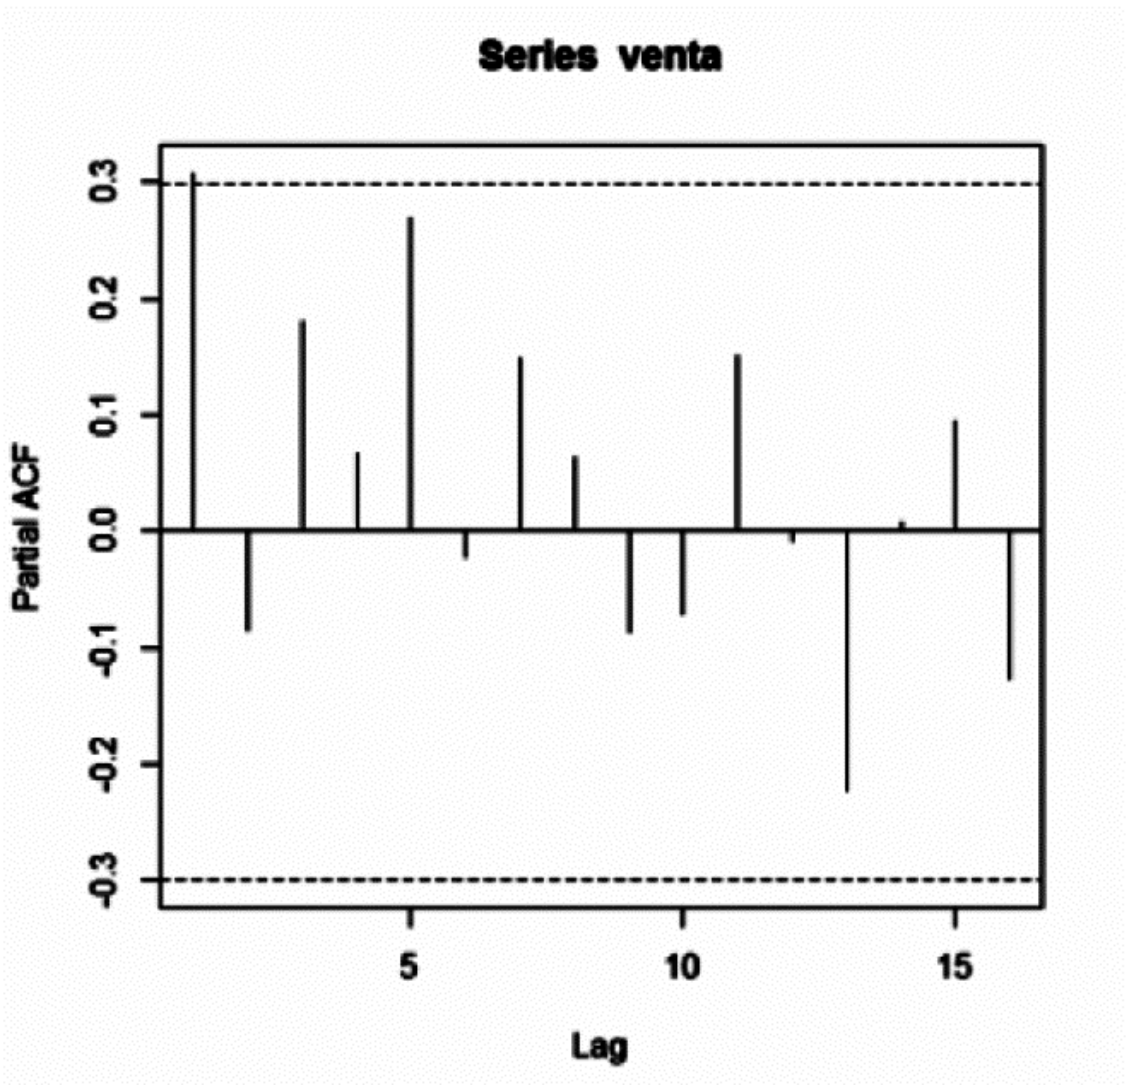

¿Cómo se visualizan los correlogramas cuando una serie no es estacionaria?

Cuando iniciamos el análisis básico de una serie de tiempo, comenzamos con su gráfico inicial, es decir, con el comportamiento de la misma serie. Se podrá observar elementos tales como:

- Una constante de origen.
- Tendencia.

Posterior a ello, se utiliza como primer herramienta de análisis de estacionaridad, la función de autocorrelación simple. Ahora, si esta última no presenta una caída exponencial, entonces se puede intuir que la serie tiene un proceso no estacionario.

Ejemplo: Serie no estacionaria

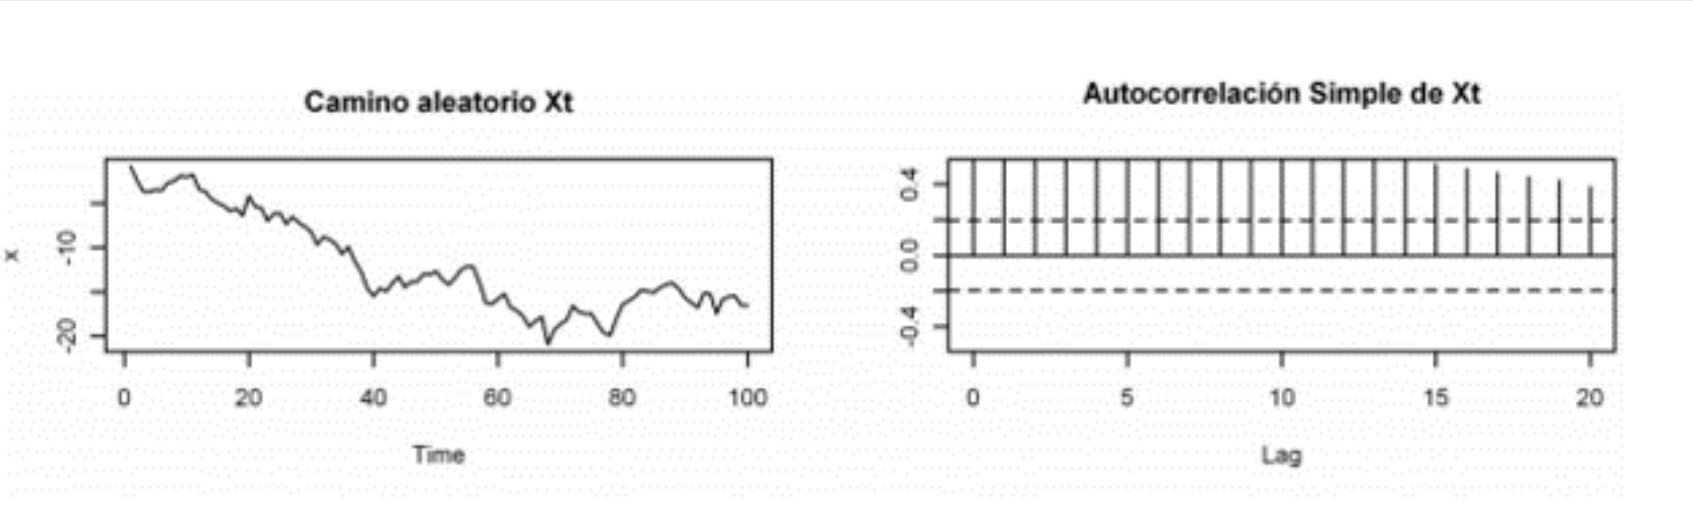

Sección 5

Pruebas estadísticas para la detección de estacionariedad

Dickey-Fuller

1. **Dickey-Fuller**

Dickey-Fuller es una prueba que consiste en regresionar un proceso AR(1) con la serie diferenciada como variable dependiente y la serie sin transformación y en un primer rezago como varibale independiente.

La desventaja de dicha prueba es qué no hay un rezago óptimo, por lo tanto el sustento de validación se basa solo en encontrar la significancia de los parámetros usados en la regresión auxiliar.

Hay tres tipos de prueba:

- Sin constante.
- Con constante pero sin tendencia
- Con constante y tendencia

Prueba Dickey-Fuller

a) **Dickey-Fuller sin tendencia**

$$\Delta Y_t = \delta Y_{t-1} + \varepsilon_t$$

b) **Dickey-Fuller con constante**

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \varepsilon_t$$

c) **Dickey-Fuller con tendencia y constante**

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta Y_{t-1} + \varepsilon_t$$

- Nota

$$Donde \;\; \delta : (\rho - 1)$$

Prueba Dickey-Fuller: Demostración

Para poder identificar la estimación de los modelos de Dickey-Fuller, se debe considerar o partir del siguiente modelo:

$$Y_t = \rho Y_{t-1} + u_t$$

Sin embargo, el modelo anterior no se puede estimar, es por ello que (Gujarati, 2010) menciona que el proceso de transformación del anterior modelo, solo consiste en restar la ecuación con Y_{t-1} en ambos lados, tal y como se muestra a continuación:

$$\begin{gathered} Y_t - Y_{t-1} = \rho Y_{t-1} - Y_{t-1} + u_t \\ \Delta Y_t = (\rho - 1)\, Y_{t-1} + u_t \\ \Delta Y_t = \delta Y_{t-1} + u_t \end{gathered}$$

Prueba Dickey-Fuller Aumentada ADF

Una forma de comprobar las raíces unitarias en una serie de tiempo, es a través de la prueba de Dickey-Fuller Aumentada, que consiste en estimar la siguiente regresión:

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta\, Y_{t-1} + \sum_{i=1}^{m} \alpha_i + \Delta\, Y_{t-i} + \varepsilon_t$$

La finalidad de dicha regresión es ver si los coeficientes se correlacionan entre si cada i rezagos, obteniendo **tau** como un valor critico a niveles de confianza del 99, 95 y 90 %.

ADF

La hipótesis de la prueba es:

$$H_0 : \delta = 0 \text{ Tendencia estocástica} \rightarrow \text{No estacionariedad}$$

$$H_a : \delta < 0 \text{ No tendencia estocástica} \rightarrow \text{Estacionariedad}$$

Phillips-Perron

Es una prueba similar a ADF solo que esta no es paramétrica, en ella se mejoran las matrices de varianzas para que los regresores no se correlacione. La regresión propuesta por Phillips-Perron es la siguiente:

$$Y_t = \mu + \alpha Y_{t-1} + u_t$$

$$Y_t = \mu + \beta \left(t - \frac{1}{2} T \right) + \alpha Y_t - 1 + u_t$$

- Hipotesis nula (H_0): Hay al menos una raíz unitaria (serie no estacionaria en media).

Se corrige la inconsistencia de la matriz de varianzas y covarianzas calculada mediante un procedimiento alternativo al ADF (fundado en Newey-West).

Prueba KPSS

Es una prueba formulada por Denis Kwiatkowski, Peter Phillips, Peter Schmidt y Yongcheol Shin. Su objetivo es innovar las pruebas anteriores (ADF y PP) mediante la creación de un multiplicador lagrangeano que busque medir la consistencia de la varianza de una serie de tiempo, bajo este supuesto, entonces la prueba KPSS nos dirá si la serie es estacionaria solo si su varianza es constante.

$$Y_t = \xi\, t + r_t + \varepsilon_t$$

- Donde:

$$r_t = r_{t-1} + u_t$$

Prueba KPSS

Mediante las regresiones auxiliares que se presentaron anteriormente, se formula un estadístico con la varianza de la estimación y la varianza de los residuales:

$$LM = \sum_{i=1}^{T} \left(\frac{S_t^2}{\sigma_\varepsilon^2} \right)$$

- Donde:
  - S_t^2: Varianza de la estimación MCO
  - σ_ε^2: Varianza de los errores.

Prueba KPSS

- **Hipótesis**

$$H_0 : \sigma_\varepsilon^2 = 0 \text{ Estacionariedad}$$
$$H_a : \sigma_\varepsilon^2 > 0 \text{ No estacionariedad}$$

Sección 6

¿Qué se debe hacer en caso de no presentar un proceso estacionario?

Introducción

Cuando se estudia una serie de tiempo y esta resulta no ser estacionaria, la teoría matemática y estadística, hace mención de aplicar **primeras diferencias**, lo cual es una transformación que elimina la tendencia y la constante de origen y provoca que la serie se parezca a un ruido blanco.

¿Qué son las primeras diferencias?

Consiste en una transformación matemática, basada en un procedimiento de resta entre la serie original menos un rezago de la misma. Es definido como:

$$\Delta Y_t = (Y_t - Y_{t-1})$$
$$\Delta \Delta Y_t = \Delta (Y_t - Y_{t-1}) = Y_t - 2Y_{t-1} + Y_{t-2}$$

Ejemplo de una primera diferencia

Se dice que la serie es estacionaria, ya que se comporta como un ruido blanco $wn \sim (0, \sigma^2)$:

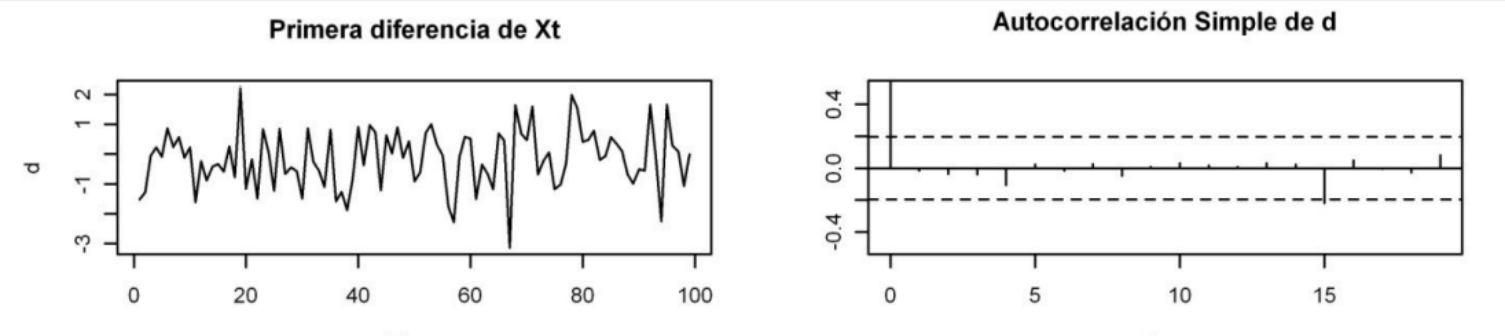

¿Qué es el orden de integración?

En términos más básicos, el orden de integración es aquel número de diferenciaciones que requiere una serie para ser estacionaria, que comúnmente se identifica con la definición ***I(d)***.

Para conocer el orden de integración, es necesario hacer las pruebas anteriores en **I(0)**, es decir, la serie sin diferenciación. Si esta resulta estacionaria, se le conoce a la serie integrada de orden 0.

Sin embargo, la mayoría de las series requieren un proceso de diferenciación y algunas requieren hasta dos diferenciaciones, por lo que **I(1)** e **I(2)** son utilizados para definir integración de orden 1 o 2.

Sección 7

Filtros de series de tiempo

Introducción

- Existen métodos de suavización que pueden ser aplicados en las series temporales. La finalidad de éstos es minimizar la varianza para poder trabajar con una serie más estable. O bien, también ayudan a mitigar el componente ciclico que genera altas varianzas o media no constante en una serie temporal.
- Dichas innovaciones en series de tiempo pueden ayudar a que las series transformadas, sean más manipulables, es decir, que se ajusten mejor a los modelos estacionarios o cualquier otro modelo dinámico.
- Además estas metodologías pueden servir para poder predecir el comportamiento futuro de la serie de tiempo mediante la tendencia de la misma o mediante innovaciones dinámicas que permiten una estimación más ***óptima***.

Introducción

- Los modelos estacionarios, no estacionarios y estacionales, son modelos paramétricos en los que se obtiene la representación de la variable en términos de su interralación temporal (MATILLA, et al, 2017).
- Los modelos de componentes inobservables se basan en la idea de que una serie temporal se puede considerar como la superposición de componentes no observables (como ciclo, varianza, étc.).

Ciclos

Concepto

Para comenzar e introducirse al filtro de Hodirck y Prescott, se debe entender un poco sobre el ciclo (ques es un concepto relacionado con la estacionalidad pero que no es lo mismo), el cual influye dentro de los fenómenos económicos o en series que se presentan factores repetitivos.

- Un ciclo consiste en expansiones, recesiones, contracciones y recuperaciones. Por lo tanto, se puede definir como una serie de repeticiones de la tendencia en ciertos periodos y que se muestran en lapsos de tiempo dentro de un intervalo de la muestra.
- El ciclo se puede expresar como una diferencia entre serie y tendencia.

Filtro de Hodrick y Prescott

- Surge de un estudio en los años 80's como consecuencia de analizar ciclos reales de la economía.
- Este filtro permite estimar la tendencia y el ciclo de una serie de tiempo, por lo que se puede deducir que dicha serie esta consistituida (formada) por estos dos elementos:

$$Y_t = C_t + T_t \;\; t = 1, \cdots, T.$$

- Para cálcula dichas estimaciones, se debe de encontrar una constante definida como λ que se refiere a un parámetro de suavidad de la tendencia y que comúnmente se expresa como un valor estándar.

Filtro de Hodrick y Prescott

- La constante del filtro Hodrick y Prescott (HP) se propone que sea elegida de acuerdo con el método de Guerrero (2008), para que la tendencia tenga un porcentaje de suavidad elegido de antemano y que se pueda comparar con los resultados en diversas aplicaciones.
- El método para series trimestrales se puede extemnder a series con otras frecuencias de observaciones (mensuales, anuales, etc.) equivalentes, que producen los mismos porcentajes de suavidad.
- El objetivo principal es ilustrar las implicaciones que conlleva el uso de distintos porcentajes de suavidad para la tendencia, en las conclusiones sobre los ciclos.

Filtro de Hodrick y Prescott

- Se define la serie de tiempo como la suma de un componente de crecimiento (que es equivalente a la tendencia) y un ciclo.

$$Y_t = g_t + c_t \;\; \forall t = 1, 2, 3, \cdots, T.$$

- Existe un proceso de optimización particular: Minimizar la varianza del componente cícliclo y la varianza de la segunda diferencia del componente de tendencia.

$$min_{\{gt\}_{t=-1}^{T}} \left\{ \sum_{t=1}^{T} c_t^2 + \lambda \sum_{t=1}^{T} \left[(g_t - g_{t-1}) - (g_{t-1} - g_{t-2}) \right]^2 \right\} \quad (1)$$

Filtro de Hodrick y Prescott

- El factor de suavizado λ es:

$$\lambda = \frac{\sigma_1^2}{\sigma_2^2}$$

- La evidencia y pertinencia de los factores de suavizado λ que suguieren los autores (Hodrick y Prescott, 1997) para datos anuales es de 100 y 1600 para datos trimestrales, aunque también se sabe que para series mensuales el factor es de 14400.
- Sin embargo, la crítica proviene de que el parámetro λ presenta una serie de inconsistencias.

Filtro de Hodrick Prescott

1. Los componentes ciclo y tendencia presentan desviaciones prominentes cuando el estimador λ no es consistente.

2. Los ciclos reales son espurios ya que se derivan de la sobreidentificación del orden de las series de tiempo.
3. Las varianzas del ciclo y la tendencia corresponden a series particulares, es decir, asumir fenómenos *a priori* en los factores de suavizado pueden perturbar inferencias.

Filtro de Hodrick Prescott

La propuesta de HP para una correcta estimación es la siguiente:

- Identificar puntualmente el orden de integración de la tendencia y proceder a utilizar la varianza correspondiente.
- Considerar y ponderar el factor λ por un coeficiente inverso de *frecuencia angular* :

$$\lambda = fa\frac{\sigma_1^2}{\sigma_2^2}$$

- Donde:

$$fa = \left[\frac{\tau}{T}\right]^{-1}$$

Filtro de Hodrick Prescott

- En términos de Hodrick y Prescott (1997):

$$y_t = (y_1, y_2, \cdots, y_t) \quad y_t \in R^T$$
$$g_t \in R^T$$
$$c_t \in R^T$$
$$y_t = g_t + c_t$$

- Si el factor suavizado no es negativo $\lambda > 0$, la descomposición de la serie y_t, se obtiene minimizando la suma ponderada de cuadrados con respecto a g_t:

$$||y - g||^2 + \lambda||\Delta^2 - g||^2 \quad \lambda \in R^T$$

Filtro de Hodrick Prescott

- La solución única de la minimización se define como:

$$g\left(\lambda, y\right)\left[I + \lambda Z^{'} Z\right]^{-1} y$$

- Donde Z denota una matriz particular de dimensión $(T - 2 \times T)$, e I indica una matriz de identidad:

$$Z_{T-2\times T} = \begin{bmatrix} 1 & -2 & 1 & \cdots & \cdots & 0 \\ 0 & 1 & -2 & 1 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & \cdots & \cdots & 1 & -2 & 1 \end{bmatrix}$$

Filtro de Hodrick Prescott

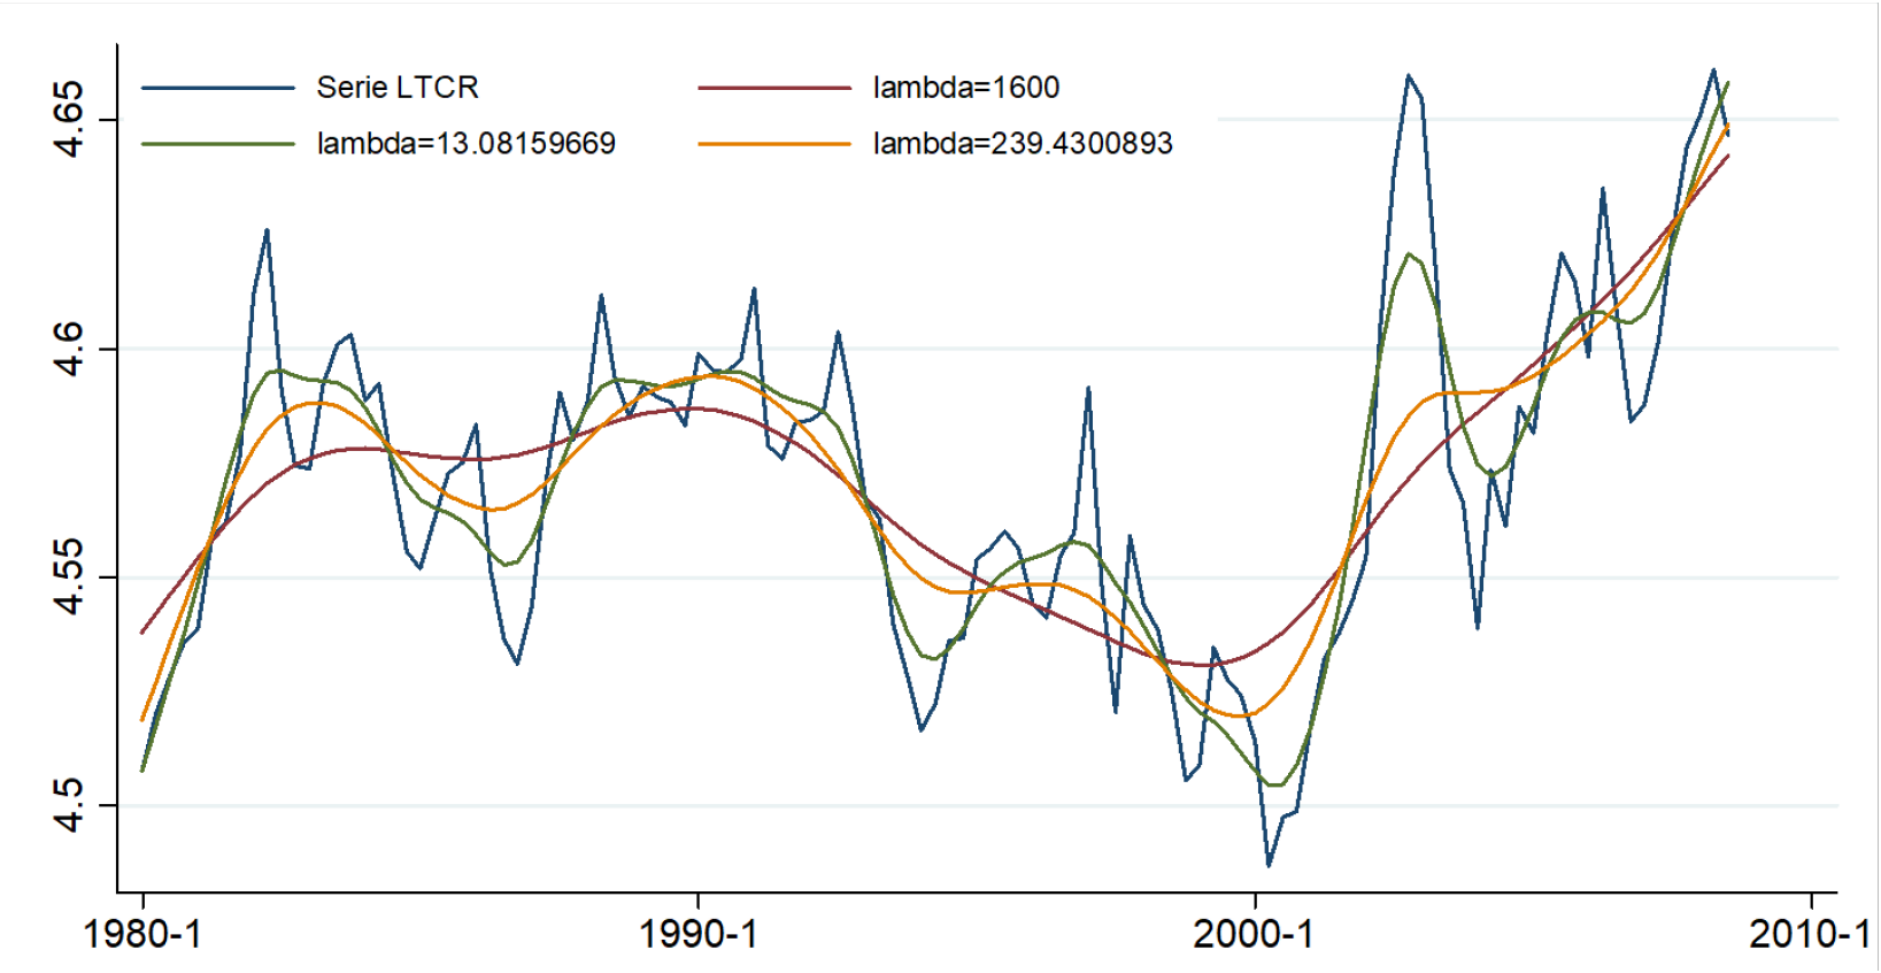

Promedios móviles

- Dentro de los métodos de alisado o *suavizamiento*, se encuentran las medias móviles (no hay que confundirlo con el modelo de medias móviles).
- Este método tiene diversas aplicaciones, por lo cual puede ser útil si se desea obtener la tendencia de una serie temporal, sin tener que ajustarse a una función previa.
- Al realizar lo anterior, se obtiene una serie suavizasa o alisada ya que al promediar varios valores, se elimina la parte ciclica o los móvimientos irregulares.

Promedios móviles

- Existen dos tipo de medias móviles: La centrada y la no centrada (asimétrica). La primera se utiliza para la representación de la tendencia, mientras que la segunda solo se aplicará para poder predecir la serie mediante la tendencia.
- Hay que recordar, que estos métodos estan sustentados mediante **el modelo clásico de descomposición** y que por consiguiente, la comprensión del método clásico permite entender mejor los métodos actuales.

Promedios móviles: Centrada

- Se caracterizan porque el número de observaciones que entran en su cálculo es impar, asignándose cada media móvil a la observación central. Así, una media móvil centrada en t de longitud $2n+1$:

$$\hat{T}_t = \frac{1}{m}\sum_{i=-k}^{k} Y_{t+i} \text{ donde } m = 2k+1$$

Promedios móviles: Centrada

- La estimación de la tendencia en el momento t se obtiene promediando los valores de la serie de tiempo, utilizando k desfases hacia atrás y k valores hacia adelante de su periodo central t.
- Este promedio elimina en gran parte la aleatoriedad de la serie, dejando un componente más suavizado.
- Se denominará al promedio móvil centrado de orden m como $m-MA$.

Ejemplo

Cuadro 1: Producción de cemento.

Años	Cemento	3-MA	9-MA
1980	19724.00		
1981	18487.00	18914.00	
1982	18531.00	18314.66	
1983	17926.00	17565.00	
1984	16238.00	16902.66	18732.74
1985	16544.00	17006.46	19432.91
1986	18237.40	18339.46	20553.42
1987	20237.00	20381.56	21694.11
1988	22670.30	22977.62	22596.89
1989	26025.56	25755.80	23319.45
1990	28571.56	27798.11	24152.09
1991	28797.23	27806.60	24954.42
1992	26051.01	25863.09	25453.30

Ejemplo

Cuadro 2: Producción de cemento.

Años	Cemento	3-MA	9-MA
1993	22741.03	24276.61	25911.56
1994	24307.79	24079.05	26463.17
1995	25458.33	24741.02	27136.00
1996	24726.96	25659.96	28207.27
1997	26794.60	27503.88	29996.11
1998	30990.09	30803.89	32371.53
1999	34626.98	34685.23	34836.58
2000	38438.64	38405.40	37341.55
2001	42150.58	41569.68	40317.41
2002	44119.82	44164.54	
2003	46223.24	46115.39	
2004	48003.11	48578.66	
2005	51509.64		

Ejemplo

El primer valor de la columna denominada **3-MA** de las tablas anteriores, se calcula de la siguiente forma: $18914 = (19724 + 18478 + 18531)/3$, y el primero de la columna **9-MA**, $18732.74 = (19724 + 18487 + 18531 + 17926 + 16238 + 16544 + 18237.4 + 20237 + 22670.3)/9$.

Promedios móviles: Centrada

- El orden de la media móvil m, determina la suavidad de la estimación. En general, un orden mayor implica una curva más suave.
- Los promedios simples son de orden impar. De esta forma se consigue que sean símetricos en su punto medio t: En un promedio móvil de orden impar $m = 2k + 1$, hay k observaciones anteriores, y k posteriores a la observación que se promedia t. Pero si m fuera par, la media ya no sería simétrica.

Promedios móviles: No centrada

- Por su parte, en el caso de las medias móviles asimétricas (no centradas) se asigna cada media móvil al periodo correspondiente de la observación más adelantada, de todas las que intervinen en su cálculo. Así, la media móvil asimétrica de *n* puntos esta asociada a la observación t.

$$MMA\,(n) = \frac{y_{t-n} + y_{t-n+1} + \cdots + y_t}{n}$$

Ejemplo

Cuadro 3: Refrescos vendidos por día

Día	Venta	MMA(3)
1	20	
2	23	
3	24	22.33
4	25	24
5	30	26.33
6	35	30
7	40	35
8	50	41.66

Ejemplo

- El cálculo de la primera media es: $(20+23+24)/3$, pero si el lector es observador, los promedios se irán recorriendo de un dato en un dato, con la finalidad de que se pueda obtener una media en el día 8 de la venta.
- A diferencia de la media móvil centrada, se toman valores pasados y futuros para calcular el promedio móvil y no solo pasados tal y como lo hace la media móvil asimétrica.

¿Cómo se visualizan ambos tipos de media móvil?

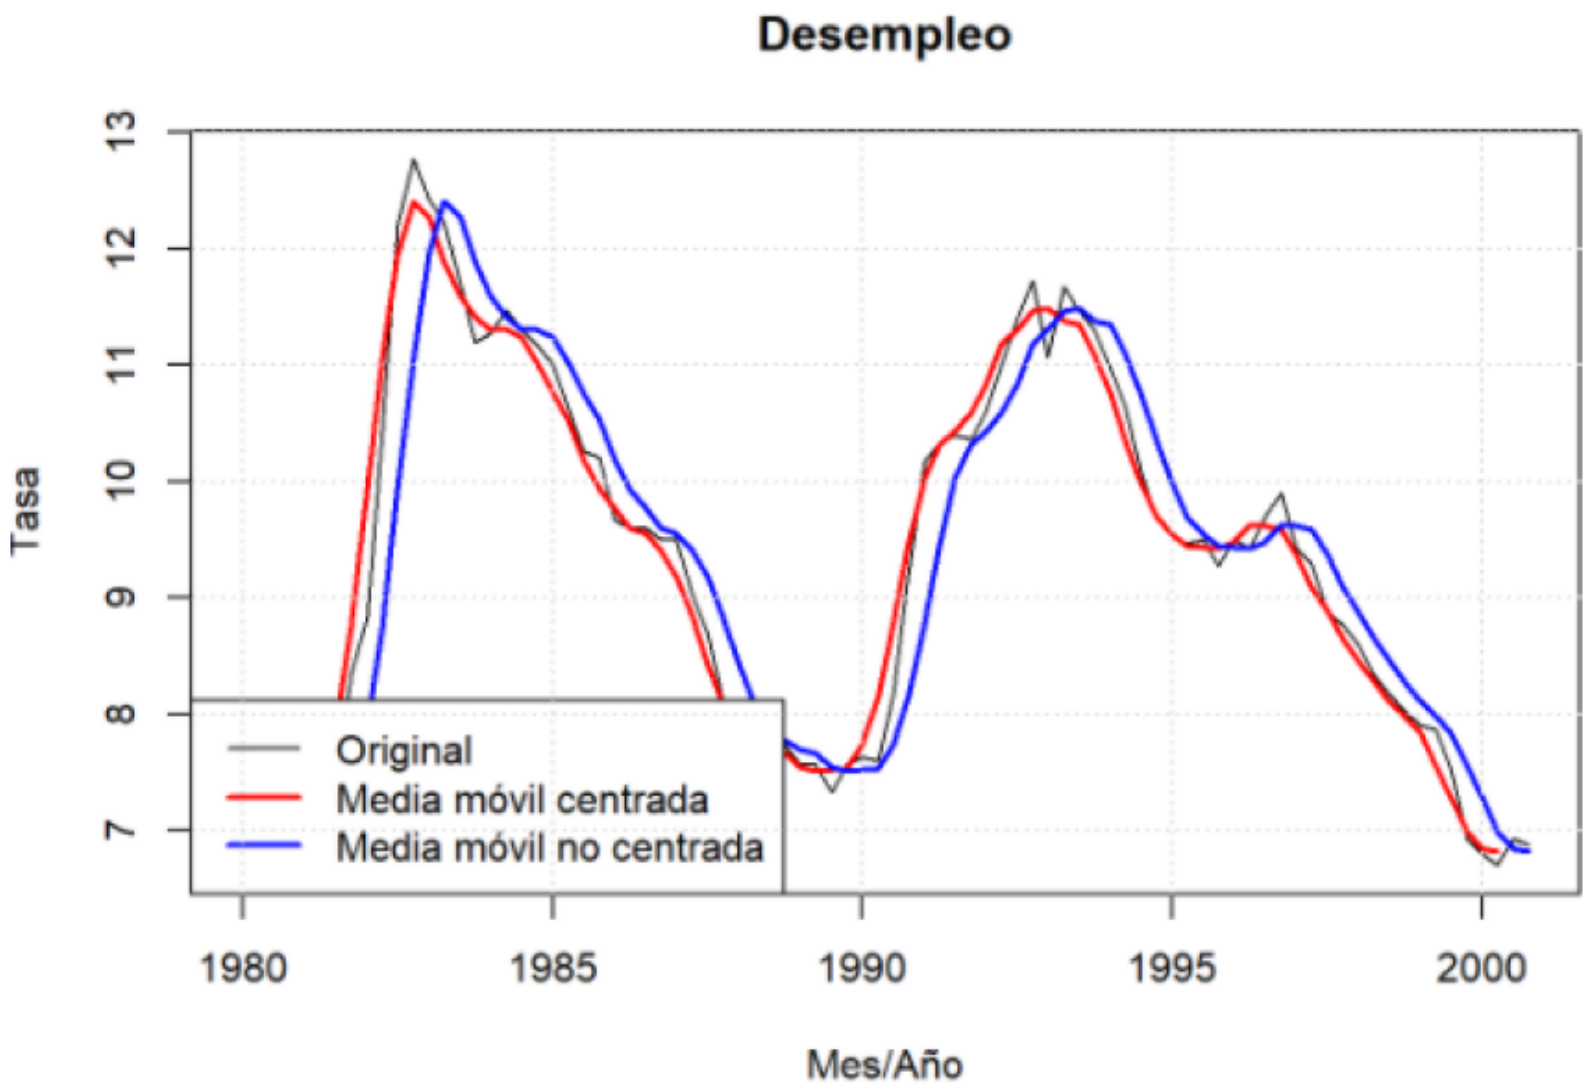

Alisado exponencial de Holt

- Antes de retomar el filtro de **Holt-Winters**, vale la pena repasar en qué consiste el alisado de **Holt**.
- El alisado exponencial con tendencia lo planteó Holt (1957), partiendo del AES (Alisado Exponencial Simple) y añadiendo una tendencia lineal, por lo tanto, la ecuación se plantea de la siguiente manera:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + h * b_t$$
$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)(n_{t-1} + b_{t-1})$$
$$\text{Tendencia } b_t = \beta^* (n_t - n_{t-1}) + (1-\beta^*) b_{t-1}$$

Alisado exponencial de Holt

- Donde n_t es la ecuación de nivel de la serie; b_t la pendiente estimada de la tendencia; α el parámetro de suavizado del nivel, $0 \leq \alpha \leq 1$; y β^* el parámetro de suavizado de la tendencia $0 \leq \beta^* \leq 1$.
- Al igual que el AES, la ecuación de nivel muestra que n_t es un promedio ponderado de la observación Y_t y la estimación del valor anterior, en este caso $Y_{t|t-1} = n_{t-1} + b_{t-1}$.
- La ecuación de tendencia indica que b_t es un promedio ponderado de la tendencia en el momento $t, n_t - n_{t-1}$ y b_{t-1}, la estimación de tendencia de la observación anterior.

Alisado exponencial de Holt

- La previsión ya no es constante, sino una tendencia lineal con b_t como pendiente de la recta de previsión y el nivel, n_t, como ordenada en el origen.
- La ecuación de corrección de errores es:

$$n_t = n_{t-1} + b_{t-1} + \alpha e_t b_t$$
$$n_t = b_{t-1} + \alpha\beta^* e_t;$$
$$\text{Donde } e_t = Y_t - (n_{t-1} + b_{t-1}) = Y_t - \hat{Y}_{t|t-1}$$

Alisado con tendencia exponencial de Holt

- Una variante del método de Holt consiste en introducir los componentes, tendencia y nivel, de una forma multiplicativa (en vez de aditiva), la ecuación por componentes es:

$$\text{Prónostico } \hat{Y}_{t+h|T} = n_t * b_t^h$$
$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)\left(n_{t-1} * n_{t-1}\right)$$
$$\text{Tendencia } b_t = \beta^* \frac{n_t}{n_{t-1}} + (1-\beta^*)\, b_{t-1}$$

- Donde b_t es la tasa de crecimiento constante de predicción (es decir, se considera el crecimiento en términos relativos en vez de términos absolutos).

Alisado con tendencia exponencial de Holt

- La tendencia ahora es exponencial en vez de lineal.
- La ecuación de corrección de error es:

$$n_t = n_{t-1} * b_{t-1} + \alpha e_t$$
$$b_t = b_{t-1} + \alpha\beta^* \frac{e_t}{n_{t-1}}$$

Donde: $e_t = Y_t - (n_{t-1} * b_{t-1}) = Y_t - \hat{Y}_{t|t-1}$

Alisado con tendencia lineal amortiguada

- En muchas ocasiones los métodos de alisado exponencial con tendencia, lineal o exponencial, tienen a sobreestimar las previsiones, especialmente a largo plazo, por ello Ladiray y Quenneville (2001) introdujeron un parámetro que amortiguara la tendencia.
- El métdo consiste en intriducir un término de ϕ que este entre 0 y 1 $0 \leq \phi \leq 1$, que amortigua la tendencia hasta convertirla en una constante. Es decir, al incluir el término de ϕ se amortiguara la tendencia y la previsión convergerá a $n_t + \frac{\phi b_t}{1-\phi}$ cuando $h \to \infty$.

Alisado con tendencia lineal amortiguada

- La ecuación por componentes adivitos es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + \left(\phi + \phi^2 + \cdots + \phi^h\right) b_t$$
$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)\left(n_{t-1} + \phi b_{t-1}\right)$$
$$\text{Tendencia } b_t = \beta^* \left(n_t - n_{t-1}\right) + \left(1-\beta^*\right) \phi b_{t-1}$$

- Si $\phi = 1$ el método es idéntico al lineal de Holt. Para valores entre 0 y 1, ϕ amortigua la tendencia hasta convertirse en una constante en el futuro lejano.

Alisado con tendencia lineal amortiguada

- Por consiguiente las previsiones a corto plazo presentan una tendencia amortiguada mientras que las previsiones a largo o muy largo plazo son constantes. La ecuación de corrección de errores es:

$$n_t = n_{t-1} + \phi b_{t-1} + \alpha e_t$$
$$b_t = \phi b_{t-1} + \alpha \beta^* e_t$$

Alisado con tendencia exponencial amortiguada

- Cuando se condiera la intriducción de los componentes de forma multiplicativa, la forma por componentes es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t * b_t^{(\phi+\phi^2+\cdots+\phi^h)}$$
$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)\, n_{t-1} * b_{t-1}^{\phi}$$
$$\text{Tendencia } b_t = \beta^* \frac{n_t}{n_{t-1}} + (1-\beta^*)\, b_{t-1}^{\phi}$$

- La ecuacón de corrección de errores es:

$$n_t = n_{t-1} * b_{t-1}^{\phi} + \alpha e_t$$
$$b_t = b_{t-1}^{\phi} + \alpha\beta^* \frac{e_t}{n_{t-1}}$$

Alisado estacional de Holt-Winters

- Holt (1957); Winters (1960) extendieron el método de Holt para capturar el componente estacional. El método estacional de Holt-Winters comprende la ecuación de pronóstico y tres ecuaciones de componentes.
  1. Nivel: n_t.
  2. Tendencia: b_t.
  3. Estacional: s_t.
- Con parámetros de suavizado α, β^* y γ. Se utiliza m para denominar el núemero de periodos estacionales del año, por ejemplo. Para datos trimestrales $m = 4$, para datos mensuales $m = 12$ y así sucesivamente.

Alisado estacional de Holt-Winters

- Hay dos variaciones del método que difieren en la naturaleza del componente estacional. La referencia es al método aditivo, ya que cuando las variaciones estacionales son más o menos constantes en toda la serie, mientras.
- La segunda variación es referente al método multiplicativo, ya que cuando las variaciones estacionales cambian proporcionalmente con el nivel de la serie.
- Con el método aditivo, el componente estacional se expresa en términos absolutos en la escala de la serie observada y en la ecuación de nivel de la serie se ajusta estacionalmente restando el componente estacional.

Alisado estacional de Holt-Winters

- Dentro de cada año, la suma de los m valores del componente estacional es aproximadamente cero.
- Con el método multiplicatuvo, el componente estacional se expresa en términos relativos (porcentakes) y la serie se ajusta estacionalmente dividiendo por el componente estacional.
- Dentro de cada año, la suma de los índices estacionales multiplicativos es aproximadamente igual a m.

Holt-Winters aditivo

- La ecuación por componentes del método aditivo es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + h * b_t + s_{t-m+h_m^+}$$
$$\text{Nivel } n_t = \alpha\left(Y_t - s_{t-m}\right) + (1-\alpha)\left(n_{t-1} + b_{t-1}\right)$$
$$\text{Tendencia } b_t = \beta^*\left(n_t - n_{t-1}\right) + \left(1-\beta^*\right) b_{t-1}$$
$$\text{Estacionalidad } s_t = \gamma\left(Y_t - n_{t-1} - b_{t-1}\right) + (1-\gamma)\, s_{t-m}$$

- Donde $h_m^+ = [(h-1)\, mod\, m] + 1$, garantiza que las estimaciones de los índices estacionales utilizados para pronosticar provengan del último año muestral.

Holt-Winters aditivo

- La ecuación de nivel es una media ponderada entre la observación desestacionalizada $(Y_t - s_{t-m})$ y la previsión desestacionalizada $(n_{t-1} + b_{t-1})$ para el momento t.
- La ecuación de tendencia es la tendencia lineal de Holt. La ecuación de estacionalidad es una media ponderada entre el actual índice de estacionalidad, $(Y_t - n_{t-1} - b_{t-1})$, y el índice de estacionalidad anterior.

Holt-Winters aditivo

- La ecuación del componente estacional suele expresarse como:

$$s_t = \gamma(Y_t - n_{t-1}) + (1-\gamma)\, s_{t-m}$$

- Si se sustituye n_t de la ecuación de suavizado para el nivel de la fórmula, por componentes anterior, se obtiene:

$$s_t = \gamma * (1-\alpha)\,(Y_t - n_{t-1} - b_{t-1}) + [1 - \gamma * (1-\alpha)]\, s_{t-m}$$

Holt-Winters aditivo

- La ecuación anterior, es identica a la ecuación de suavizado para el componente estacional que se especifico con $\gamma = \gamma^*(1-\alpha)$. La restricción de parámetro usual es que $0 \leq \gamma \leq 1$, lo que se traduce en que $0 \leq \gamma \leq 1-\alpha$.
- La forma de corrección es:

$$n_t = n_{t-1} + b_{t-1} + \alpha e_t$$
$$b_t = b_{t-1} + \alpha\beta^* e_t$$
$$s_t = s_{t-m} + \gamma e_t$$

Donde: $e_t = Y_t - (n_{t-1} + b_{t-1} + s_{t-m}) = Y_t - \hat{Y}_{t|t-1}$

Holt-Winters multiplicado

- La forma de componente para el método multiplicativo es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = (n_t + h * b_t) * s_{t-m+h_m^+}$$

$$\text{Nivel } n_t = \alpha \left(\frac{Y_t}{s_{t-m}} \right) + (1-\alpha)(n_{t-1} + b_{t-1})$$

$$\text{Tendencia } b_t = \beta^* (n_t - n_{t-1}) + (1-\beta^*) b_{t-1}$$

$$\text{Estacionalidad } s_t = \gamma \left(\frac{Y_t}{n_{t-1} + b_{t-1}} \right) + (1-\gamma) s_{t-m}$$

Holt-Winters multiplicado

- La represntación de correción de errores:

$$n_t = n_{t-1} + b_{t-1} + \alpha \frac{e_t}{s_{t-m}}$$

$$b_t = b_{t-1} + \alpha\beta^* \frac{e_t}{s_{t-m}}$$

$$s_t = s_{t-m} + \gamma \frac{e_t}{n_{t-1} + b_{t-1}}$$

Donde: $e_t = Y_t - (n_{t-1} + b_{t-1})\, s_{t-m} = Y_t - \hat{Y}_{t|t-1}$

Holt-Winters amortiguado

- En ocasiones el método de pronóstico más preciso para las series de tiempo estacionales es el método de Holt-Winters con una tendencia amortiguada y estacionalidad multiplicativa, su expresión por componente es:

$$\text{Prónostico } \hat{Y}_{t+h|T} = \left(n_t + \phi + \phi^2 + \cdots + \phi^h\right) * s_{t-m+h_m^+}$$

$$\text{Nivel } n_t = \alpha\left(\frac{Y_t}{s_{t-m}}\right) + (1-\alpha)\left(n_{t-1} + \phi b_{t-1}\right)$$

$$\text{Tendencia } b_t = \beta^*\left(n_t - n_{t-1}\right) + \left(1-\beta^*\right)\phi b_{t-1}$$

$$\text{Estacionalidad } s_t = \gamma\left(\frac{Y_t}{n_{t-1} + \phi b_{t-1}}\right) + (1+\gamma)\, s_{t-m}$$

Filtro de Kalman

- El filtro de Kalman es un procedimiento recursivo cuyo objetivo es calcular estimadores óptimo del vector estado en un momento de tiempo t, utilizando toda la información disponible hasta el momento t.
- Es decir, conocidas las observaciones de la serie Y_t hasta el momento t; los valores de z, C, R, Q, σ^2 y los valores iniciales (a_0, P_0). El método o algoritmo recursivo se puede dividir en dos grupos de ecuaciones.

Filtro de Kalman

1. Ecuaciones de predicción, que obtienen un predictor óptimo del vector estado y de la próxima observación: Dados los valores a_t y P_t obtenemos $a_{t+1|t}$, $Y_{t+1|t}$, $P_{t+1|t}$.

2. Ecuaciones de actualización que incorporan la nueva observación Y_{t+1} en la estimación del vector de estado: Dada la nueva observación Y_{t+1} obtenemos a_{t+1}, P_{t+1}.

Filtro de Kalman

Las ventajas del filtro son:

- Permite actualiza la estimación del vector estado continuamente según se van obteniendo nuevas observaciones.
- Produce predictores óptimos, en el sentido de *ECM* mínimo.
- El filtro tiene algoritmos además que permite estimar los componentes, mediante la denominada *extracción de señales*, utilizando toda la información de la muestra.
- Cuando las perturbaciones se distribuyen normalmente, se puede construir la función de verosimilitud, estimar los parámetros desconocidos y realizar constrastes diagnóstico y especificación.

Filtro de Kalman

Forma general del filtro de Kalman:

- Considerando el modelo invariable en el tiempo, se tiene:

$$Y_t = z\alpha_t + d + e_t$$
$$\alpha_t = C\alpha_{t-1} + g + R_t\eta_t$$

- Donde:

$$\begin{bmatrix} e_t \\ \eta_t \end{bmatrix} \sim NID\left[0, \begin{bmatrix} \sigma^2 & 0 \\ 0 & Q \end{bmatrix}\right]$$
$$cov\left(e_t, a_{t-k}\right) = 0 \ \forall k \geq 0 \ \ a_0 \sim N\left(a_0, P_0\right)$$
$$E\left(e_t\eta_t\right) = 0 \ E\left(e_t a_t\right) = 0 \ E\left(\eta_t a_t\right) = 0 \ \forall t, s$$

Filtro de Kalman

- El conjunto de ecuaciones que forman el filtro se dividen en ecuaciones de predicción que proporcionan el predictor óptimo para el vector de estado a_{t+1} con toda la información hasta t, y las ecuaciones de actualización permiten incorporar la nueva información disponible dentro del estimador del vector estado.
- Sea a_{t-1} el estimador óptimo de a_{t-1}, basado en todas las observaciones disponibles hasta Y_{t-1}. Denotemos P_{t-1} a la matriz de covarianzas del error de estimación del vector de estado:

$$P_{t-1} = E\left[\left(\alpha_{t-1} - a_{t-1}\right)\left(\alpha_{t-1} - a_{t-1}\right)'\right]$$

Filtro de Kalman

- Dados a_{t-1} y P_{t-1}, el estimador óptimo de α_t junto con su *ECM* viene dado por las ecuaciones de predicción:

$$a_{t|t-1} = Ca_{t-1} + e$$
$$P_{t|t-1} = CP_tC' + RQR'$$

- Dada esta estimación del vector estado en el momento t con información hasta el momento $t-1$, se puede obtener la predicción del valor futuro Y_t:

$$Y_{t|t-1} = za_{t|t-1} + d$$

Filtro de Kalman

- El error de predicción correspondiente es:

$$\xi_t = Y_t - Y_{t|t-1} = Y_t - z a_{t|t-1} - d = z\left(\alpha_t - a_{t|t-1}\right) + e_t$$

- Estos errores de predicción se denominan *innovacione* ya que representan la nueva información contenida en la última observación.

Filtro de Kalman

- Cuando llega la nueva observación Y_t, el estimador de α_t, $a_{t|t-1}$, junto con su matriz de **ECM**, se puede actualizar, mediante las ecuaciones de actualización:

$$a_t = a_{t|t-1} + P_{t|t-1} z f_t^{-1} \left(Y_t - z a_{t|t-1} - d \right)$$
$$P_{t|t-1} = P_{t|t-1} - P_{t|t-1} z f_t^{-1} P_{t|t-1}$$

- Donde:

$$f_t = z P_{t|t-1} z^{'} + \sigma^2$$

- Se puede observar que las innovaciones tienen un papel fundamental en la actualización del vecto estado. Cuanto más alejado esté el error ξ_t del vector nulo, mayor será la corrección en el vector estado. Además se observa que f_t no es más que la varianza del error de pedicción.

Filtro de Kalman

- Las ecuaciones de predicción junto con las actualización conforman el filtro. Este se puede especificar también como un solo conjunto de recursiones:

$$a_{t|t-1} = C\left[a_{t|t-1} + P_{t|t-1} z f_t^{-1}\left(Y_t - z a_{t|t-1} - d\right)\right] + e$$
$$P_{t|t-1} = C\left[P_{t|t-1} - P_{t|t-1} z^{'} f_t^{-1} z P_{t|t-1}\right] C^{'} + RQR^{'}$$

- Operando se tiene:

$$a_{t|t-1} = C a_{t|t-1} + k_t\left(Y_t - z a_{t|t-1} - d\right) + e$$
$$P_{t|t-1} = C\left[P_{t|t-1} - P_{t|t-1} z^{'} f_t^{-1} z P_{t|t-1}\right] C^{'} + RQR^{'}$$

Filtro de Kalman

- Donde:

$$k_t = CP_{t|t-1} z f_t^{-1}$$

- Es conocida como la *ganancia de Kalman*. La ecuación de recursión para el vecto estado se puede escribir como una combinación lineal de la nueva observación y de la última estimación:

$$a_{t+1|t} = (C - kz)\, a_{t|t-1} + k_t Y_t$$

Filtro de Kalman

- La recursión para la matriz de covarianzas del error de estimación se conoce como *ecuación de Ricatti*.
- Los valores indiciales dek filtro se pueden especificar en términos de a_0 y P_0 y/o de $a_{1|0}$ y $P_{1|0}$. Dadas las condiciones inciales, el filtro proporciona el estimador óptimo del vector estado según va llegando cada nueva observación.
- Cuando se han procesado las T observaciones, el filtro nos proporciona el estimador óptimo del vector estado en el momento T, a_T, y en el $T+1$ basado en el conjunto de información completo, $a_{T+1|T}$.
- Este estimador contiene toda la información necesaria para llevar a cabo predicciones óptimas de los valores futuros tanto de Y_t como del vector estado.

Interpretación del filtro de Kalman

- Bajo los supuestos de normalidad siguiente:

$$a_0 \sim N\left(\alpha_0, P_0\right)$$
$$\begin{bmatrix} e_t \\ \eta_t \end{bmatrix} \sim NID\left[0, \begin{bmatrix} \sigma^2 & 0 \\ 0 & Q \end{bmatrix}\right]$$

- Se puede derivar el filtro e interpretarlo. Para $t = 1$, entonces:

$$\alpha_1 = C\alpha_0 + R\eta_1$$

Interpretación del filtro de Kalman

- Donde α_1 es normal multivariante porque es una combinación lineal de variables normales y condicionado a Y_0, se tiene que la media de α_1 es:

$$a_{1|0} = Ca_0$$

- Y la matriz de covarianzas:

$$P_{1|0} = CP_0C' + RQR'$$

Interpretación del filtro de Kalman

- Con lo que la distribución condicionada es:

$$\alpha_1 | Y_0 \sim N\left(a_{1|0}, P_{1|0}\right)$$

- Donde $a_{1|0}$ es la media de α_1 condicionada a la información disponible en el momento $t = 0$.

Interpretación del filtro de Kalman

- Si conociéramos la distribución de α_1 en $t = 0$, entonces los resultados anteriores son redundantes y las condiciones iniciales vendrán dadas en términos de $a_{1|0}$ y $P_{1|0}$. Para obtener la distribución de α_1 condicionada a Y_1, se hace lo siguiente:

$$\alpha_1 = a_{1|0} + \left(\alpha_1 - a_{1|0}\right)$$
$$Y_1 = za_{1|0} + z\left(\alpha_1 - a_{1|0}\right) + e_1$$

Interpretación del filtro de Kalman

- El vector $(\alpha_1^{'}, Y_1)$ tiene una dsitribución normal con media $(a_{1|0}^{'} z a_{1|0})$ y una matriz de covarianzas:

$$\begin{bmatrix} P_{1|0} & P_{1|0} z \\ z^{'} P_{1|0} & z P_{1|0} z^{'} + \sigma^2 \end{bmatrix}$$

Interpretación del filtro de Kalman

- Aplicando el siguiente lema:

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim \left[\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix} \right]$$
$$X|Y \sim N\left(\mu_{X|Y}, \Sigma_{XX|Y}\right)$$

- Donde:

$$\mu_{X|Y} = \mu_X + \Sigma_{XX}\Sigma_{YY}^{-1}\left(Y - \mu_Y\right)$$
$$\Sigma_{XX|Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$$

Interpretación del filtro de Kalman

- Se ve que la distribución condicionaad de α_1 condicionada a Y_1 es:

$$\alpha_1 | Y_1 \sim N\left(a_1, P_1\right)$$

- Donde:

$$a_t = E\left(a_{t|Y_1, Y_2, \cdots, Y_t}\right) = E_t\left(\alpha_t\right)$$
$$P_t = \left\{\left[\alpha_t - E_{t-1}\left(\alpha_t\right)\right]\left[\alpha_t - E_{t-1}\left(\alpha_t\right)\right]'\right\}$$

Interpretación del filtro de Kalman

- Hay que considerar la media de la distribución de α_t condicionada a la información disponible en el momento t, $E_t(\alpha_t)$. La media condicionada es una estimación de α_t de Error Cuadrático Medio Minimo, en el sentido de que cualquier otra estimación tiene una matriz de ECM que se puede escribir como:

$$V = P_t + A$$

Predicción: Filtro de Kalman

- Si se conocel los parámetris del modelo, la predicción de Y_{T+1} junto con su error cuadratico medio medio vienen datos directamente por las ecuaciones de predicción del filtro de Kalman.
- En el modelo Gaussiano, el filtro de Kalman proporciona a_T, el estimador de ECM mínimo de α_T basado en todas las observaciones. Además proporciona también la predicción hacia un periodod adelante y su ECMP:

$$a_{T+1|T} = Ca_T$$
$$Y_{T+1|T} = za_{T+1|T}$$
$$ECM\left(Y_{T+1|T}\right) = zP_{T+1|T}z^{'} + \sigma_e^2$$

Predicción: Filtro de Kalman

- Ahora, el problema general de obtener predicciones de valores futuros de Y_{T+h}, $h = 1, 2, \cdots$ basadas en la información de la muestra, es decir, conocidos a_T y P_T. En el modelo Gaussiano, la predicción óptima, en el sentido de minimizar el error cuadrático medio de predicción de Y_{T+h}, $Y_T(h)$, es la esperanza condicionada:

$$Y_T(h) = E\left(Y_{T+h|Y_T, Y_{T-1}, \cdots, Y_1}\right) = z a_{T+h|T}$$

Predicción: Filtro de Kalman

- Donde:

$$a_{T+h|T} = E\left(a_{T+h|Y_T, Y_{T-1}, \cdots, Y_1}\right) = z a_{T+h|T}$$

- Y el error cuadrático medio de predicción viene dado por:

$$ECM\left(Y_{T+h|T}\right) = z^{'} P_{T+h|T^z} + \sigma_e^2 \ \ (h = 1, 2, \cdots)$$

Predicción: Filtro de Kalman

- La mejor forma de obtener $a_{T+h|T}$ y $P_{T+h|T}$ es sustituir repetidamente las ecuaciones de predicción del filtro saltándose las de actualización (ya que no se tienen nuevas observaciones):

$$a_{T+h} = C^h \alpha_T + \sum i = 1^{h-1} C^{h-i} R \eta_{T+i} + R \eta_{T+h} \ \ (h = 2; 3, \cdots,)$$
$$E_t \left(\alpha_{T+h} \right) = a_{T+h|T} = C^h a_T$$
$$P_{T+h|T} = C^h P_t \left(C' \right)^h + \sum_{i=1}^{h-1} C^i Q \left(C' \right)^i$$

Fuentes

AGUIRRE, J. A. (1994). *Introducción al tratamiento de series temporales: Aplicación a las ciencias de la salud*. Ediciones Diaz de Santos, S.A. Madrid.

CAO, A. R. (2002). *Introducción a la simulación y a la teoría de colas*. Netbiblo, España.

CHAN, H. N. (2010). *Time series: applications to Financer with R and S-Plus*. Wiley, USA.

GUJARATI, N. D. (2010). *Econometría* (5ta. ED.). MC Graw Hill, México.

SHUMWAY, H. R. & STOFFER, S. D. (2017). *Time series analysis and its applications*. Springer, USA.

Fuentes

TSAY, S. R. (2012). *An introduction to analysis of financial data with R*. Wiley, USA.

WOODWARD, A. W, et al. (2016). *Applied time series analysis with R*. CRC Press, USA.

GUERRERO. V. (2009). *Medición de la tendencia y el ciclo de una serie de tiempo económica desde una perspectiva estadística*. Instituto Tecnológico Autónomo de México, México.

Fuentes

ANEIROS, P. G. (2008). *Series de tiempo*. Universidad da Coruña, España.

HAMILTON, D. J. (1996). *Time Series Analysis*. Princenton University Press. USA.

MARILLA, C. M. et al. (2017). *Econometría y predicción*. Mc Grawll Hill, España.

Fuentes

MINITAB. (2019). *Métodos y fórmulas para promedio móvil*. Soporte de Minitab 18. URL: https://support.minitab.com/esmx/minitab/18/help-and-how-to/modeling-statistics/time-series/howto/moving-average/methods-and-formulas/methods-and-formulas/. Consultado: 10/12/2021

PARRA, F. (2019). *Estadística y Machine Learning con R*. Libro electrónico. URL: https://bookdown.org/content/2274/portada.html. Consultado: 10/12/2021

VILLAREAL, F. (2016). *Introducción a los Modelos de Prónosticos*. Universidad Nacional del SUR, Argentina.